Probabilités avancées
Cours de Master Avancé 1, ENS Lyon

Cours de Christophe Garban

septembre-décembre 2014

Ces notes sont celles d'un cours de deuxième année donné à l'ENS Lyon en 2014. Elles ont été rédigées par P. UMBER (conditionnement et chaînes de Markov) et M. DUSSAULE (martingales). Les erreurs qui s'y trouvent ne sont aucunement du fait de C. Garban. D'autre part, même s'il s'agit essentiellement du cours de C. Garban, on pourra trouver des notes prises à partir d'autres cours, typiquement pour la démonstration de certains résultats que C. Garban n'a pas eu le temps de prouver. Ces autres notes proviennent principalement de [3]. D'ailleurs, selon les mots de l'enseignant, ce cours est très proche de [3]. Il en diffère cependant par les exemples et par quelques digressions.

Ce cours, sobrement intitulé probabilités avancées, développe la théorie des chaînes de Markov et des martingales. Il s'agit donc plus spécifiquement d'un cours sur les processus aléatoires à temps discrets. On commencera par quelques rappels en théorie générale des probabilités, notamment sur les questions de conditionnement, qui interviendront tout au long du cours.

Table des matières

1 Espérance conditionnelle **2**
1.1 Préambule . . . 2
1.2 Espérance conditionnelle . . . 2
1.3 Propriétés plus spécifiques de l'espérance conditionnelle . . . 4

2 Chaînes de Markov **4**
2.1 Définition et premières propriétés . . . 4
2.2 Chaîne de Markov canonique et propriétés de Markov . . . 8
2.3 Classification des états . . . 11
2.4 Chaînes de Markov et mesures invariantes . . . 14

3 Martingales **22**
3.1 Martingales, sur-martingales, sous-martingales . . . 22
3.2 Convergence(s) des martingales . . . 25
3.3 Quelques résultats sur les temps d'arrêts . . . 31
3.4 Martingales rétrogrades . . . 32

Intoduction

Commençons ce cours par un exemple simple. Considérons la marche aléatoire d'un cavalier sur un échiquier, partant de la case en bas à gauche x_0, et notons X_n la variable aléatoire qui prend en compte la position du cavalier au temps n. Notons enfin T le premier temps de retour du cavalier en x_o. Le but de l'excercice est de calculer l'espérance $\mathbb{E}[T]$. On peut montrer que cette espérance est finie et même calculer sa valeur :

$$\mathbb{E}[T] = \sum_{n\geq 1} \mathbb{P}(T=n)n = \sum_{npair} \mathbb{P}(T=n)n = 2\frac{1}{6} + .. = 168.$$

Nous verrons plus loin dans ce cours comment y arriver une fois les bons outils développés. L'idée est, comme en théorie ergodique, de considérer une moyenne temporelle que l'on veut réexprimer en moyenne spatiale, considérer une suite de mesures μ_n et de considérer sa "limite" μ_∞. L'objet de ce cours est plus

généralement l'étude de processus aléatoires, indéxés sur un ensemble dénombrable à valeur dans un espace mesurable $(E, \mathcal{E})$.

Exemple. On a quelques exmples issus de la vie courante, comme le CAC (mais impossible à modéliser), le relevé d'un sismographe, le casino, qui peut être modélisé via une sur-martingale (que nous verrons dans la troisième partie de ce cours), le relevé d'une bouteille à la mer, les pages web internet, ou encore le mélange d'un jeu de cartes.

Exemple. On a aussi des exemples plus mathématiques, comme l'étude d'une suite de varaiables aléatoires indépendantes, à veleur dans $\mathbb{R}$ et considérer la suite des sommes partielles, une marche aléatoire dans un graphe, dans un groupe, ou encore l'étude du processus de branchement de type Galton-Watson.

1 Espérance conditionnelle

1.1 Préambule

Définition 1.1.1. Soit $(E, \mathcal{E})$ un espace mesurable. Une **filtration de** $(E, \mathcal{E})$ est une suite croissante $(\mathcal{F}_n)$ de sous-tribus de $\mathcal{E}$. L'espace $(E, \mathcal{E}, (\mathcal{F}_n))$ est appelé **espace mesurable filtré** et si $\mathbb{P}$ est une probabilité sur Ω, on dit que $(\Omega, \mathcal{E}, (\mathcal{F}_n), \mathbb{P})$ est une **espace de probabilité filtré**.

Exemple. On considère l'espace mesurable $(E, \mathcal{E}) = ([0,1], \mathcal{B}([0,1]))$ que l'on muni de la **filtration dyadique** donnée par $\mathcal{F}_0 = \{\emptyset, [0,1]\}$, $\mathcal{F}_1 = \{\emptyset, [0, \frac{1}{2}], [\frac{1}{2}, 1], [0,1]\}$ ...

1.2 Espérance conditionnelle

On fixe $(\Omega, \mathcal{F}, \mathbb{P})$ un espace de probabilité.

Théorème 1.2.1. *Soient X une variable aléatoire dans $L^1(\Omega, \mathcal{F}, \mathbb{P})$ et $\mathcal{G}$ une sous-tribu de $\mathcal{F}$. Alors il existe une uique variable aléatoire Z dans $L^0(\Omega, \mathcal{G}, \mathbb{P})$, telle que Z est dans $L^1(\Omega, \mathcal{G}, \mathbb{P})$ et :*

$$\forall B \in \mathcal{G}, \mathbb{E}[X \mathbb{1}_B] = \mathbb{E}[Z \mathbb{1}_B].$$

*Z est appelée **espérance conditionnelle de X sachant $\mathcal{G}$** et on la note $\mathbb{E}[X|\mathcal{G}]$.*

Remarque. De manière équivalente, $\mathbb{E}[X|\mathcal{G}]$ est l'unique variable aléatoire dans $L^1(\Omega, \mathcal{G}, \mathbb{P})$ telle que, pour tout Y variable aléatoire $\mathcal{G}$-mesurable bornée, $\mathbb{E}[XY] = \mathbb{E}[\mathbb{E}[X|\mathcal{G}]Y]$.

Cette propriété est appelée **propriété caractéristique de l'espérance conditionnelle**. On notera que l'espérance conditionnelle est une variable aléatoire, et que si X est déjà $\mathcal{G}$-mesurable, alors on a la relation $\mathbb{E}[X|\mathcal{G}] = X$.

Définition 1.2.1. Avec les mêmes notations, si (Y_i) est une famille de variables alétoires, on pose $\mathbb{E}[X|(Y_i)] := \mathbb{E}[X|\sigma((Y_i))]$.

On peut interpréter $\mathbb{E}[X|Y]$ de la manière suivante : Si ω est un point de Ω, choisi au hasard, dont la seule information que l'on dispose est la valeur $Y(\omega)$, alors $\mathbb{E}[X|Y](\omega)$ est la valeur moyenne de X en prenant compte de l'information $Y(\omega)$, comme déterminer la température moyenne d'un lieu en prenant compte de son altitude.

Définition 1.2.2. Soit $A \in \mathcal{F}$, on pose $\mathbb{P}(A|\mathcal{G}) := \mathbb{E}[\mathbb{1}_A|\mathcal{G}]$ que l'on appelle **probabilité conditionnelle de A sachant $\mathcal{G}$**.

Exemple. Si Ω est la population Française et $\mathcal{G}$ est la tribu engendrée par l'ensemble B_1 des personnes qui vivent en Île de France et B_2 l'ensemble de celles qui vivent dans le Rhône, en notant T le temps moyen de transport par jour, alors $\mathbb{E}[T|\mathcal{G}] = \mathbb{1}_{B_1} 2h + \mathbb{1}_{B2} 1h + \mathbb{1}_{\Omega - B_1 \cup B_2} 15min$.

Exemple. Si f est une fonction L^1 sur $]0,1]$, $\mathcal{G}_n$ est la filtration dyadique, et si l'on pose $I_{n,i} :=]\frac{1-i}{2^n}, \frac{i}{2^n}]$, alors $\mathbb{E}[f|\mathcal{G}_n] = \sum_{i=1}^{2^n} 2^n \int_{I_{n,i}} f \, \mathbb{1}_{I_{n,i}}$. Cela approxime la fonction f par des rectangles.

Pour pouvoir démontrer ce théorème, nous allons dans un premier temps démontrer une version L^2 du théorème de l'espérance conditionnelle.

Théorème 1.2.2. *Soient X une variable aléatoire dans $L^2(\Omega, \mathcal{F}, \mathbb{P})$ et $\mathcal{G}$ une sous-tribu de $\mathcal{F}$. Alors il existe une unique variable aléatoire Z dans $L^2(\Omega, \mathcal{G}, \mathbb{P})$ et qui vérifie*

$$\forall Y \in L^2(\Omega, \mathcal{G}, \mathbb{P}), \mathbb{E}[XY] = \mathbb{E}[ZY].$$

On notera encore $\mathbb{E}[X|\mathcal{G}]$ la variable Z. Si de plus X est positive, alors Z l'est aussi.

Démonstration. Commençons par montrer l'unicité. Si Z et Z' sont deux variables qui vérifient le théorème, alors, on pose $B := \{Z > Z'\} \in \mathcal{G}$. On a $\mathbb{E}[X\mathbb{1}_B] = \mathbb{E}[Z\mathbb{1}_B] = \mathbb{E}[Z'\mathbb{1}_B]$ donc $\mathbb{E}[(Z - Z')\mathbb{1}_{Z>Z'}] = 0$. Ainsi on a $Z \leq Z'$ presque sûrement. De même, $Z' \leq Z$, donc $Z = Z'$ presque sûrement. Pour l'existence, on sait que L^2 est un espace d'Hilbert, et $L^2(\Omega, \mathcal{G}, \mathbb{P})$ est un sous-espace fermé de $L^2(\Omega, \mathcal{F}, \mathbb{P})$ car complet. Ainsi, on a la décomposition $L^2(\Omega, \mathcal{F}, \mathbb{P}) = L^2(\Omega, \mathcal{G}, \mathbb{P}) \oplus L^2(\Omega, \mathcal{G}, \mathbb{P})^\perp$. On note π la projection orthogonale sur $L^2(\Omega, \mathcal{G}, \mathbb{P})$, et l'on pose $Z := \pi(X)$. Soit $Y \in L^2(\Omega, \mathcal{G}, \mathbb{P})$, on a alors :

$$\begin{aligned}
\mathbb{E}[XY] &= \langle X, Y \rangle \\
&= \langle \pi(X) + (X - \pi(X)), Y \rangle \\
&= \langle \pi(X), Y \rangle \\
&= \mathbb{E}[ZY]
\end{aligned}$$

Ceci montre l'existence. Démontrons la dernière proposition : Si $\mathbb{P}(\mathbb{E}[Z|\mathcal{G}] < 0) > 0$, alors il existe $\epsilon > 0$ tel que $\mathbb{P}(\mathbb{E}[Z|\mathcal{G}] < -\epsilon) > 0$. On pose alors $B := \{\mathbb{E}[Z|\mathcal{G}] < -\epsilon\}$ qui est un élément de $\mathcal{G}$. Alors $0 < \mathbb{E}[\mathbb{E}[Z|\mathcal{G}]\mathbb{1}_B] = \mathbb{E}[Z\mathbb{1}_B] \geq 0$ ce qui est absurde, d'où le résultat. □

On peut noter deux conséquences de ce théorème :
— Si $X \in L^2(\Omega, \mathcal{G}, \mathbb{P})$, alors on a $\mathbb{E}[X|\mathcal{G}] = X$.
— Si $\mathcal{G}_1 \subset \mathcal{G}_2$ sont deux sous-tribus de $\mathcal{F}$, alors $\mathbb{E}[\mathbb{E}[X|\mathcal{G}_2]|\mathcal{G}_1] = \mathbb{E}[X|\mathcal{G}_1]$.
Passons à présent à la preuve de la première version du théorème :

Démonstration. On prouve de la même manière que dans le cas L^2 l'unicité de l'espérance conditionnelle. Intéressons-nous à l'existence : On suppose donc $X \in L^1(\Omega, \mathcal{F}, \mathbb{P})$. Supposons de plus que $X \geq 0$. On pose $X_n := X\mathbb{1}_{\{X \leq n\}}$. La suite (X_n) est croissante et chaque X_n est dans L^2 car bornée et positive, donc $\mathbb{E}[X_n|\mathcal{G}]$ est positive. On pose alors $\mathbb{E}[X|\mathcal{G}] := \lim_n \mathbb{E}[X_n|\mathcal{G}]$. La variable $\mathbb{E}[X|\mathcal{G}]$ est bien dans L^1 car $(\mathbb{E}[\mathbb{E}[X_n|\mathcal{G}]])$ converge vers $\mathbb{E}[\mathbb{E}[X|\mathcal{G}]]$ par théorème de convergence monotone et $\mathbb{E}[\mathbb{E}[X_n|\mathcal{G}]] = \mathbb{E}[X_n]$, avec $(\mathbb{E}[X_n])$ qui converge vers $\mathbb{E}[X]$ par théorème de convergence monotone. De plus, Si $B \in \mathcal{G}$, on pose $Y := \mathbb{1}_B$, alors la suite $(X_n Y)$ est croissante et converge vers XY. De même, la suite $(\mathbb{E}[X_n|\mathcal{G}]Y)$ est croissante et converge vers $\mathbb{E}[X|\mathcal{G}]Y$, on conclu donc en passant par l'espérance et en utilisant le théorème de convergence monotone. Dans le cas général, lorsque X est non positif, on décompose X en sa partie positive et négative et on conclu par linéarité. □

Proposition 1.2.3. *L'espérance conditionnelle vérifie les propriété suivantes :*
— *L'espérance conditionnelle est positive*
— *L'espérance conditionnelle est linéaire*
— $\mathbb{E}[\mathbb{E}[X|\mathcal{G}]] = \mathbb{E}[X]$
— $|\mathbb{E}[X|\mathcal{G}]| \leq \mathbb{E}[|X||\mathcal{G}]$
— *Convergence monotone conditionnelle : Si (X_n) est une suite croissante de variables aléatoires positives qui converge vers X, alors $(\mathbb{E}[X_n|\mathcal{G}])$ converge vers $\mathbb{E}[X|\mathcal{G}]$.*
— *Fatou conditionnelle : Si (X_n) est une suite de variables aléatoires positives, alors on a l'inégalité $\mathbb{E}[\liminf X_n|\mathcal{G}] \leq \liminf \mathbb{E}[X_n|\mathcal{G}]$.*
— *Jensen conditionnelle : Si ϕ est une fonction convexe positive, alors $\mathbb{E}[\phi(X)|\mathcal{G}] \geq \phi(\mathbb{E}[X|\mathcal{G}])$.*

Démonstration. Démontrons le quatrième point. On a :

$$\begin{aligned}
|\mathbb{E}[X|\mathcal{G}]| &= |\mathbb{E}[X^+|\mathcal{G}] - \mathbb{E}[X^-|\mathcal{G}]| \\
&\leq \mathbb{E}[X^+|\mathcal{G}] + \mathbb{E}[X^-|\mathcal{G}] \\
&= \mathbb{E}[|X||\mathcal{G}].
\end{aligned}$$

Démontrons le dernier point. On pose $E_\phi := \{(a,b) \in \mathbb{R}^2, \forall x \in \mathbb{R}, \phi(x) \geq ax+b\}$. Alors :

$$\begin{aligned}\mathbb{E}[\phi(X)|\mathcal{G}] &= \mathbb{E}[\sup_{(a,b)\in E_\phi \cap \mathbb{Q}} aX+b|\mathcal{G}] \\ &\geq \sup_{(a,b)\in E_\phi\cap\mathbb{Q}} \mathbb{E}[aX+b|\mathcal{G}] \\ &= \sup_{(a,b)\in E_\phi\cap\mathbb{Q}} a\mathbb{E}[X|\mathcal{G}]+b \\ &= \phi(\mathbb{E}[X|\mathcal{G}]).\end{aligned}$$

On considère la borne supérieure sur un ensemble dénombrable pour pouvoir sortir le sup de l'espérance conditionnelle. □

1.3 Propriétés plus spécifiques de l'espérance conditionnelle

Proposition 1.3.1. — *Soient X et Y deux variables aléatoires réelles telles que X et XY sont dans L^1 et Y est $\mathcal{G}$-mesurable. Alors on a la propriété de factorisation suivante : $\mathbb{E}[XY|\mathcal{G}] = Y\mathbb{E}[X|\mathcal{G}]$.*
— *Si $\mathcal{G}_1 \subset \mathcal{G}_2$ sont deux sous-tribus de $\mathcal{F}$, alors $\mathbb{E}[\mathbb{E}[X|\mathcal{G}_2]|\mathcal{G}_1] = \mathbb{E}[X|\mathcal{G}_1]$.*

Démonstration. Pour le premier point, on peut supposer X et Y positive, et soit Z une variable aléatoire positive $\mathcal{G}$-mesurable. On a $\mathbb{E}[(\mathbb{E}[X|\mathcal{G}]Y)Z] = \mathbb{E}[(\mathbb{E}[X|\mathcal{G}])YZ] = \mathbb{E}[XYZ] = \mathbb{E}[\mathbb{E}[XY|\mathcal{G}]Z]$. On a donc le résultat. Le deuxième point se traite de manière analogue. □

Proposition 1.3.2. *Soit $\mathcal{G}_1$ et $\mathcal{G}_2$ deux sous-tribus de $\mathcal{F}$. Alors : $\mathcal{G}_1$ et $\mathcal{G}_2$ sont indépendantes si et seulement si pour tout X variable aléatoire positive $\mathcal{G}_1$-mesurable, on a $\mathbb{E}[X|\mathcal{G}_2] = \mathbb{E}[X]$.*

Démonstration. On suppose $\mathcal{G}_1$ et $\mathcal{G}_2$ indépendantes. Soient $B \in \mathcal{G}_1$, $A \in \mathcal{G}_2$. On a

$$\mathbb{E}[\mathbb{1}_B\mathbb{1}_A] = \mathbb{E}[\mathbb{1}_{A\cap B}] = \mathbb{E}[\mathbb{1}_A]\mathbb{E}[\mathbb{1}_B] = \mathbb{E}[\mathbb{E}[\mathbb{1}_A]\mathbb{1}_B],$$

donc $\mathbb{E}[\mathbb{1}_B|\mathcal{G}_2] = \mathbb{E}[\mathbb{1}_B]$, puis l'égalité est encore vraie pour toute variable aléatoire positive.

Réciproquement, si pour tout X variable aléatoire positive $\mathcal{G}_1$-mesurable, on a $\mathbb{E}[X|\mathcal{G}_2] = \mathbb{E}[X]$, considérons $B \in \mathcal{G}_2$, $A \in \mathcal{G}_1$. Par hyposthèse, on a $\mathbb{P}(A) = \mathbb{E}[\mathbb{1}_A|\mathcal{G}_2]$, donc

$$\mathbb{P}(A\cap B) = \mathbb{E}[\mathbb{1}_A\mathbb{1}_B] = \mathbb{E}[\mathbb{E}[\mathbb{1}_A|\mathcal{G}_2]\mathbb{1}_B] = \mathbb{P}(A)\mathbb{P}(B).$$

□

Corollaire 1.3.3. *Si X et Y sont deux variables aléatoires positives ou dans L^1 alors X et Y sont indépendantes si et seulement si, pour toute fonction numérique h positive, on a $\mathbb{E}[h(X)|Y] = \mathbb{E}[h(X)]$. Ainsi, si X et Y sont indépendantes, avec X positive ou dans L^1, alors $\mathbb{E}[X|Y] = \mathbb{E}[X]$. Cette dernière proposition n'est cependant pas une équivalence.*

Notons pour terminer une expression de l'espérance conditionnelle dans le cas où Y est une variable aléatoire à valeur dans un ensemble E dénombrable et X une variable aléatoire dans L^1. Alors on a $\mathbb{E}[X|Y] = \phi(Y)$ où ϕ est une fonction de E dans $\mathbb{R}$ telle que, pour $y \in E$, $\phi(y) = \frac{1}{\mathbb{P}(Y=y)}\mathbb{E}[X\mathbb{1}_{\{Y=y\}}]$ si $\mathbb{P}(Y=y) > 0$ et prend une valeur quelconque sinon, $\mathbb{E}[X|Y]$ étant de toute façon définie à un ensemble de mesure nulle près.

2 Chaînes de Markov

Dans tout ce chapitre, E sera un ensemble fini ou dénombrable, dit **espace d'états**.

2.1 Définition et premières propriétés

Définition 2.1.1. Une **matrice de transition** ou **matrice stochastique** est une matrice Q indexée sur E telle que : $\forall x, y \in E, Q(x,y) \in [0,1]$ et $\forall x \in E, \sum_{y\in E} Q(x,y) = 1$.

Définition 2.1.2. Soient Q une matrice de transition et (X_n) un processus aléatoire. La suite (X_n) est une **chaîne de Markov de matrice de transition** Q si pour tout n et pour tous $x_0, .., x_n \in E$, si $\mathbb{P}(X_0 = x_0, .., X_n = x_n) > 0$, alors

$$\forall y \in E, \mathbb{P}(X_{n+1} = y | X_0 = x_0, .., X_n = x_n) = Q(x_n, y).$$

Cette propriété est dite **propriété de Markov**. On parle aussi d'**absence de mémoire**. On montre facilement que cette propriété est équivalente à la suivante :

pour tout n et pour tous $x_0, .., x_n \in E$,

$$\mathbb{P}(X_0 = x_0, .., X_n = x_n) = \mathbb{P}(X_0 = x_0)Q(x_0, x_1)..Q(x_{n-1}, x_n).$$

Avec la seconde forme de la propriété de Markov, on voit qu'une chaîne de Markov de matrice de transition Q est entièrement déterminée par sa condition initiale, c'est-à-dire la donnée des $\mathbb{P}(X_0 = x_0)$.

Définition 2.1.3. Soit (X_n) une chaîne de Markov. On définit la **loi initiale de la chaîne de Markov** par $\mu_0 : x_0 \longmapsto \mathbb{P}(X_0 = x_0)$. Le couple (Q, μ_0) est appelé **mécanisme de transition**. On pose aussi $\mu_n := \mathbb{P}_{X_n}$.

Exemple. Soit (X_n) une chaîne de Markov de matrice de transition Q. Si $p \geq 1$ est un entier et si l'on pose $Y_n := X_{np}$, alors (Y_n) définie une chaîne de Markov de matrice de transition Q^p.

Remarque. On verra plus tard une manière canonique de construire une chaîne de Markov en se donnant un mécanisme de transition.

On considère à présent (X_n) une chaîne de Markov de matrice de transition Q sur l'espace E.

Proposition 2.1.1.
— $\mu_n = \mu_0 Q^n$
— *Pour toute fonction positive bornée de E dans $\mathbb{R}$, on a $\mu_n(f) = \mathbb{E}_{\mu_0}[f(X_n)] = \mu_0 Q^n f$.*

Remarque. On a utilisé dans la dernière proposition la notation naturelle matricielle où les mesures sont des vecteurs lignes et les fonctions sont des vecteurs colonnes.

Démonstration. Démontrons par exemple la première proposition : soit $y \in E$. On a

$$\begin{aligned}
\mu_n(y) &= \sum_{x_0 \in E} \mathbb{P}(X_0 = x_0, X_n = y) \\
&= \sum_{\substack{x_0, .., x_n \in E \\ x_n = y}} \mathbb{P}(X_0 = x_0, .., X_n = x_n = y) \\
&= \sum_{\substack{x_0, .., x_n \in E \\ x_n = y}} \mu_0(x_o) Q(x_0, x_1)..Q(x_{n-1}, y) \\
&= \mu_0 Q^n(y).
\end{aligned}$$

□

Exemple. Considérons la chaîne de Markov à deux états a et b de matrice de transition définie par $Q = \begin{pmatrix} \epsilon & 1-\epsilon \\ 1-\epsilon & \epsilon \end{pmatrix}$, avec $\epsilon \in]0, 1[$. On pose $\mu_0 := \delta_a$. On a alors $\mu_1 = \epsilon\delta_a + (1-\epsilon)\delta_b$. En itérant, on peut montrer que (μ_n) converge en loi vers $\frac{1}{2}\mu_a + \frac{1}{2}\mu_b$. On remarque que pour $\epsilon = 0$ il n'y a pas convergence de la mesure.

Définition 2.1.4. Soit μ une mesure positive non nulle sur E, finie en chaque point. La mesure μ est dite **invariante pour** Q si $\mu Q = \mu$.

Proposition 2.1.2. *Soit (Q, μ_0) un mécanisme de transition. On suppose qu'il existe une mesure de probabilité π telle que la suite (μ_n) converge en loi vers π, alors π est une mesure invariante pour Q.*

Démonstration. Soit f une fonction réelle bornée définie sur E, alors comme la suite (μ_n) converge en loi vers π, $\mu_n(f)$ converge vers $\pi(f)$. Par ailleurs, $\mu_n(f) = \mu_0 Q^n f$ et $\mu_{n+1}(f) = \mu_0 Q^n Q f$ et Qf est bornée car Q est une matrice stochastique, donc $\pi(f) = \pi(Qf)$, donc $\pi = \pi Q$. □

Remarque. Il se peut que Q admette une mesure invariante mais que le système ne converge pas vers cette mesure.

Exemple. — Si (X_n) est une suite de variables aléatoires indépendantes identiquement distribuées de loi μ, alors (X_n) est une chaîne de Markov de matrice de transition définie par $Q(x,y) = \mu(y)$.

— Si G est un graphe connexe localement fini (non orienté), la marche aléatoire associée à G est donnée par la matrice de transition

$$Q(x,y) = \frac{1}{\deg(x)} \mathbb{1}_{x \sim y}$$

où $\deg(x)$ est le nombre d'arrêtes qui partent de x et $\mathbb{1}_{x\sim y}$ le lieu caractéristique des sommets adjacents à x. Si le graphe est fini, on pose

$$\mu(x) := \frac{\deg(x)}{\sum_{y \in G} \deg(y)},$$

alors, on vérifie que μ est une mesure Q-invariante.

— Soit G est un groupe de type fini, engendré par $g_1, ..g_n$. Si Γ est le graphe de Cayley associé à ce système de générateurs, c'est-à-dire le graphe dont les sommets sont les points de G et les arrêtes sont de la forme (g, sg) où g est dans le groupe et s est l'un des g_i, alors la marche aléatoire sur G associée à ce système de générateurs est la marche aléatoire sur le graphe Γ.

— On considère le processus de branchement de type Galton-Watson donné par

$$Z_{n+1} = \sum_{i=1}^{Z_n} \xi_{n+1,i},$$

où les $\xi_{n,i}$ sont des variables aléatoires indépendantes identiquement distribuées de loi μ sur E, avec ici $E = \mathbb{N}$. Alors (Z_n) est une chaîne de Markov sur $\mathbb{N}$ de matrice de transition

$$Q(x,y) = \mathbb{P}(Z_{n+1} = y | Z_n = x) = \mu^{*x}(y) = \sum_{a_1 + .. + a_x = y} \mu(a_1)...\mu(a_x).$$

— On pose $E = (\mathbb{N}^*)^2$ et on considère la matrice de transition $(Q((a,b),(a',b')))$ donnée par

$$Q((a,b),(a+1,b)) := \frac{a}{a+b},\ Q((a,b),(a,b+1)) := \frac{b}{a+b}.$$

On a ainsi défini le modèle de **l'urne de Polya**. On considère une urne remplie de boules de deux couleurs. À chaque étape, on prend une boule dans l'urne, que l'on remet et on ajoute une boule de la même couleur dans l'urne.

— On fixe N un entier non nul, on pose $E = \{0, .., N\}$. On pose alors

$$Q(n, n+1) := \frac{N-n}{N}, n < N$$

et

$$Q(n, n-1) := \frac{n}{N}, n > 0.$$

On parle ici **d'urne de Ehrenfest**. Si

$$\mu(n) := 2^{-N} \binom{N}{n}$$

, alors μ est une mesure invariante.

Définition 2.1.5. Q est dite **irréductible** si

$$\forall x, y \in E, \exists k \geq 1, Q^k(x,y) > 0.$$

Exemple. Si E est l'ensemble des cases d'un échiquier, le mouvement d'un cavalier et d'une tour est irréductible mais celui du fou ne l'est pas.

Proposition 2.1.3. *On suppose que Q est irréductible. Soit π une mesure Q-invariante. Alors π ne s'annule pas.*

Démonstration. Comme π est non nulle par définition, considérons $x \in E$ tel que $\pi(x) > 0$. Alors si $y \in E$, comme Q est irréductible, on peut considérer k tel que $Q^k(x,y) > 0$. On a alors

$$\pi(y) = \sum_{z \in E} \pi(z) Q^k(z,y) \geq \pi(x) Q^k(x,y) > 0.$$

□

Définition 2.1.6. Soit $x \in E$, on pose $\Gamma(x) := \{n \geq 1, Q^n(x,x) > 0\}$.

On pose aussi $d(x) := \mathbf{pgcd}\{\Gamma(x)\}$, avec la convention $\Gamma(\emptyset) = \infty$. On dit que $d(x)$ est **la période de** x .

Proposition 2.1.4. *On suppose que Q est irréductible. Alors $\exists d \geq 1, \forall x \in E, d(x) = d$. L'entier d est la **période de la chaîne de Markov**. Si $d = 1$, on dit que la chaîne de Markov est **apériodique**.*

Démonstration. Soient $x, y \in E$. La chaîne étant irréductible, on peut choisir k, l tels que $Q^k(x,y) > 0$ et $Q^l(y,x) > 0$. Alors $m := k + l \in \Gamma(x) \cap \Gamma(y)$, car on a les inégalités $Q^m(x,x) \geq Q^k(x,y)Q^l(y,x) > 0$ et $Q^m(y,y) \geq Q^l(y,x)Q^k(x,y) > 0$. Ainsi, $d(x)|m$ et $d(y)|m$. Par ailleurs, si $n \in \Gamma(x)$, alors

$$Q^{n+m}(y,y) \geq Q^l(y,x)Q^n(x,x)Q^k(x,y) > 0,$$

donc $n + m \in \Gamma(y)$. Ainsi, $\Gamma(x) + m \subset \Gamma(y)$, donc $\Gamma(x) \subset \Gamma(y) - m$ donc $d(y)|d(x)$. De même, $d(x)|d(y)$ donc $d(x) = d(y)$. □

On va s'intéresser à la convergence vers une mesure invariante dans la cas où E est fini.

Proposition 2.1.5. *On suppose que E est fini. Alors Q admet une mesure invariante.*

Démonstration. D'un point de vue matriciel, trouver une mesure invariante pour Q revient à trouver un vecteur propre à gauche de Q de valeur propre 1. On remarque que le vecteur colonne de taille n (où n est le cardinal de E) qui n'a que des 1 est un vecteur propre à droite de Q car Q est une matrice stochastique. Comme le spectre de Q est le même que Q^t, on en déduit que Q admet un vecteur propre à gauche de valeur propre 1. Par ailleurs, on cherche un vecteur propre à coefficient positif de somme égale à 1 pour avoir une mesure Q-invariante.

On pose $\Delta^{n-1} := \{x \in \mathbb{R}^n, x_i \geq 0 \text{ et } \sum_{i=1}^{n} x_i = 1\}$, qui est compact convexe non vide, et l'on définit la fonction $\Phi : x \in \Delta^{n-1} \mapsto xQ \in \Delta^{n-1}$, alors Φ est continue, donc admet un point fixe dans Δ^{n-1} d'après le théorème de point fixe de Brouwer, d'où le résultat.

Donnons une seconde preuve plus ergodique du résultat. Soit μ_0 une mesure de probabilité sur E. On pose $\mu_n := \mu_0 Q^n$ et $\pi_n := \dfrac{1}{n} \sum_{i=0}^{n} \mu_i$. Comme Δ^{n-1} est compact, il existe une extractrice ϕ telle que $\pi_{\phi(n)}$ converge vers une mesure de probabilité π. Par ailleurs, $\pi_{\phi(n)} = \pi_{\phi(n)} + \frac{1}{\phi(n)+1}(\mu_{\phi(n)+1} - \mu_0)$ donc, par continuité de Φ, on a $\pi Q = \pi$. □

Proposition 2.1.6. *On suppose E fini. Alors le rayon spectral de Q est égal à 1.*

Démonstration. On pose $\|x\| := \max_i |x_i|$. La norme subordonnée associée à cette norme sur les matrices de taille n est

$$\|M\| = \max_i \sum_j |Q_{i,j}|.$$

Ainsi, comme Q est une matrice stochastique, on a $\|Q^n\|^{\frac{1}{n}} = 1$. Comme les normes subordonées sont des normes d'algèbres, par le théorème du rayon spectral de Gelfand, on a $\rho(Q) = 1$. □

On peut aussi utiliser le théorème de Perron Frobenius, qui sera admis ici, et qui donne un résultat plus précis :

Théorème 2.1.7. *Soit A une matrice de taille n à coefficients positifs et irréductible. Alors il existe une valeur propre λ de A telle que $\lambda = \rho(A)$. λ est dit valeur propre de Perron. De plus, λ est une valeur propre simple, et admet un vecteur propre $\pi > 0$, et tout autre vecteur propre $\pi' > 0$ de A est proportionnel à π. Si A est de période d, les seules valeurs propres μ de module égal à λ sont les $e^{\frac{2i\pi}{d}}\lambda$ et elles sont toutes simples.*

On peut donc conclure que, si E est fini et si Q est irréductible, alors la chaîne de Markov admet une unique mesure invariante. On verra plus tard dans un cas plus général l'unicité de cette mesure invariante. On a aussi une vitesse de convergence pour le cas apériodique :

Proposition 2.1.8. *On suppose que E est fini et Q est irréductible apériodique.*
On pose $\alpha := \sup\{|\lambda|, \lambda \neq 1, \lambda \in \boldsymbol{Sp}(Q)\}$. Alors :
— $\alpha < 1$
— $\forall \mu_0, \forall \beta > \alpha, \forall p \in [1; +\infty], \exists C, \|\mu_n - \pi\|_p \leq C\beta^n$ *pour n assez grand, où π est l'unique mesure invariante. Ainsi, on peut dire qu'il y a convergence exponentielle.*

Démonstration. Le premier point est une conséquence du théorème de Perron-Frobenius. Pour le second point, on note v le vecteur de $\mathbb{R}^n$ dont les coefficients sont tous 1. Comme les coefficients de π sont tous strictement positifs, π n'est pas dans $v^\perp$, donc $\mathbb{R}^n = Vect(\pi) \bigoplus v^\perp$. On remarque que $v^\perp$ est un sous-espace stable à gauche de Q. En effet, si $x \in v^\perp$, on a $(xQ)v = x(Qv) = x \cdot v = 0$. Donc $v^\perp$ est un sous-espace stable à droite de Q^t, et comme $\mathbb{R}^n = Vect(\pi) \bigoplus v^\perp$, Q est équivalente à la matrice

$$\begin{pmatrix} 1 & 0 \\ 0 & B \end{pmatrix},$$

où B est une matrice carré de taille $n-1$. Par le théorème de Perron Frobenius, le rayon spectral de B est $\alpha < 1$.

À présent, on écrit $\mu_0 = \lambda\pi + x$ avec $x \in v^\perp$. On a $\mu_0 v = 1 = \lambda\pi v = \lambda$ donc $\mu_0 = \pi + x$. Comme π est invariante, on a $\mu_n = \pi + xQ^n = \pi + x(B^t)^n$. Par ailleurs, par le théorème de Gelfand, on a

$$\alpha = \rho(B) = \rho(B^t) = \lim_n \|(B^t)^n\|^{\frac{1}{n}},$$

donc $\|\mu_n - \pi\|_p \leq \|x\|_p \|(B^t)^n\|_p \leq \|x\|_p \beta^n$ pour n assez grand. Ainsi, $C := \|x\|_p$ convient. □

2.2 Chaîne de Markov canonique et propriétés de Markov

On s'intéresse à présent au cas général où E est infini. Soit donc (Q, μ_0) un mécanisme de transition sur E.

Exemple. Il n'existe pas toujours de mesure invariante non nulle, comme par exemple dans le cas où $E = \mathbb{N}$ et, pour $n \geq 0, Q(n, n+1) = 1$.

Pour étudier ce cas général, on commence par construire un processus dit canonique qui réalise la loi de la chaîne de Markov induite par (Q, μ_0).

Théorème 2.2.1. *On peut définir un processus aléatoire (X_n) sur un espace $(\Omega', \mathbb{P}')$ qui réalise la loi de la chaîne de Markov induite par (Q, μ_0).*

Démonstration. On pose $\Omega := [0, 1[$ muni de la mesure de Lebesgue. Dans un premier temps, montrons qu'il existe une suite de variables aléatoires indépendantes identiquement distribuées de loi $\mathcal{U}([0, 1])$. Soit $\omega \in [0, 1[$, alors on peut écrire

$$\omega = \sum_{n \geq 0} \epsilon_n(\omega) 2^{-n-1},$$

où ϵ_n vaut 0 ou 1. Ainsi, on a la donné d'une suite (ϵ_n) de variables aléatoires indépendantes identiquement distribuées telle que $\mathbb{P}(\epsilon_n = 1) = \mathbb{P}(\epsilon_n = 0) = \frac{1}{2}$. Soit $\phi : \mathbb{N} \times \mathbb{N} \to \mathbb{N}$ une bijection. On pose $\eta_{i,j} := \epsilon_{\phi(i,j)}$ et

$$U_i := \sum_{j \geq n} \eta_{i,j} 2^{-j-1}.$$

Alors (U_i) est une suite de variables aléatoires indépendantes identiquement distribuées de loi $\mathcal{U}([0, 1])$. En effet, si $p \in \mathbb{N}^*, \sum_{j=0}^{p} \eta_{i,j} 2^{-j-1}$ a la même loi que $\sum_{j=0}^{p} \epsilon_n 2^{-j-1}$.

On note $E = \{y_i\}_{i \in \mathbb{N}^*}$. Soit X'_0 la variable aléatoire à valeur dans E telle que $\mathbb{P}_{X'_0} = \mu_0$.
On pose alors

$$X'_{n+1} := y_k \text{ si } \sum_{j=1}^{k-1} Q(X'_n, y_j) < U_{n+1} \leq \sum_{j=1}^{k} Q(X'_n, y_j).$$

On a alors :

$$\mathbb{P}'(X'_{n+1}=y_k|X'_0=x_0,..,X'_n=x_n)=\mathbb{P}'(\sum_{j=1}^{k-1}Q(x_n,y_j)<U_{n+1}\leq\sum_{j=1}^{k}Q(x_n,y_j)|X'_0=x_0,..,X'_n=x_n)$$
$$=\mathbb{P}'(\sum_{j=1}^{k-1}Q(x_n,y_j)<U_{n+1}\leq\sum_{j=1}^{k}Q(x_n,y_j)).$$

La dernière égalité a lieu car la famille (U_i) est indépendante.
Ainsi, $\mathbb{P}'(X'_{n+1}=y_k|X'_0=x_0,..,X'_n=x_n)=Q(x_n,y_k)$ car U_{n+1} est la loi uniforme sur $[0,1[$ et que

$$\sum_{j=1}^{k}Q(x_n,y_j)-\sum_{j=1}^{k-1}Q(x_n,y_j)<U_{n+1}=Q(x_n,y_k).$$

On a donc le résultat. □

Voyons à présent une seconde construction, dîte canonique. On pose $\Omega:=E^{\mathbb{N}}$ et $\mathcal{F}:=\mathcal{P}(E)^{\otimes\mathbb{N}}$. On note $X_n:\Omega\longrightarrow E$ la n-ème projection canonique (on parle de **processus des coordonnées**). On rappelle que $\mathcal{F}=\sigma(X_n|n\in\mathbb{N})$.

Théorème 2.2.2. *Il existe une unique mesure de probabilité $\mathbb{P}_{\mu_0}$ sur Ω telle que, sous $\mathbb{P}_{\mu_0}$, le processus des coordonnées est une chaîne de Markov induite par (Q,μ_0).*

Démonstration. On reprend les notations de la première construction. On pose $\Phi:(\Omega',\mathcal{F}',\mathbb{P}')\longrightarrow(\Omega,\mathcal{F})$ définie par $\omega'\mapsto(X'_n(\omega'))_{n\in\mathbb{N}}$ et l'on défini $\mathbb{P}_{\mu_0}$ comme la mesure poussée en avant par Φ. Comme $X_n\circ\Phi=X'_n$ est mesurable, Φ est mesurable (conséquence de la tribu produit sur Ω). On a :

$$\begin{aligned}\mathbb{P}_{\mu_0}(X_0=x_0,..,X_n=x_n)&=\mathbb{P}'(X'_0=x_0,..,X'_n=x_n)\\&=\mathbb{P}'(X'_0=x_0)Q(x_0,x_1)..Q(x_{n-1},x_n)\\&=\mu_0(x_0)Q(x_0,x_1)..Q(x_{n-1},x_n),\end{aligned}$$

ce qui montre l'existence. L'unicité est laissé en exercice. □

Soit $x\in E$. Lorsque $\mu_0=\delta_x$, on note $\mathbb{P}_x$ la mesure donnée par la construction qui précède. Si A est un évènement de Ω, alors $\mathbb{P}_x(A)$ peut s'interpréter comme la probabilité que l'évènement A se réalise en partant de l'état x. On remarque alors que :
— si $y\in E$, on a $\mathbb{P}_x(X_n=y)=Q^n(x,y)$
— si μ est une mesure de probabilité sur E, on a $\mathbb{P}_\mu=\sum_{x\in E}\mu(x)\mathbb{P}_x$.

A présent, essayons de dégager les avantages de la chaîne de Markov canonique.

Définition 2.2.1. Soit $k\in\mathbb{N}$. On pose $\theta_k:\Omega\longrightarrow\Omega$ défini par $(\omega_i)\mapsto(\omega_{i+k})$: **opérateur de translation** ou **shift**.

Proposition 2.2.3. *L'opérateur θ_k est mesurable.*

Définition 2.2.2. On pose $\mathcal{F}_n:=\sigma(X_0,..,X_n)$. On dit que $(\mathcal{F}_n)$ est la **filtration canonique sur** Ω.

Définition 2.2.3. Soit G une application mesurable définie sur Ω à valeur dans $[0,+\infty]$ ou à valeur dans $\mathbb{R}$ et intégrable. On note $\mathbb{E}_\mu[G]$ l'espérance de G calculée avec la probabilité $\mathbb{P}_\mu$, et l'on adopte la même notation lorsqu'il s'agit d'une espérance conditionnelle. Plus généralement, on peut définir sur E la fonction $\varphi_G:x\mapsto\mathbb{E}_x[G]$. On pose alors $\mathbb{E}_{X_n}[G]:=\varphi_G(X_n)$, qui est une variable aléatoire à valeur dans $[0,+\infty]$ ou réelle, et qui s'interprète comme étant l'espérance de G en partant de l'état X_n.

Proposition 2.2.4. *Propriété de Markov simple : Soit G application mesurable définie sur Ω à valeur dans $[0,+\infty]$ ou à valeur dans $\mathbb{R}$ et intégrable. Alors $\mathbb{E}_{\mu_0}[G\circ\theta_n|\mathcal{F}_n]=\mathbb{E}_{X_n}[G]$. Autrement dit, la loi conditionnelle de θ_n sachant $\mathcal{F}_n$ est la chaîne de Markov partant de X_n.*

Démonstration. Soit $F : \Omega \longrightarrow \mathbb{R}$ une application $\mathcal{F}_n$-mesurable, intégrable.

On va montrer que $\mathbb{E}_{\mu_0}[FG \circ \theta_n] = \mathbb{E}_{\mu_0}[F\mathbb{E}_{X_n}[G]]$.

Pour cela, on va regarder le cas où

$$F = \mathbb{1}_{X_0=x_0,..,X_n=x_n}$$

(F étant $\mathcal{F}_n$-mesurable), et

$$G = \mathbb{1}_{X_0=y_0,..,X_k=y_k}$$

où $k \geq 0$ et $x_0, .., x_n, y_0, .., y_k \in E$; on pourra alors conclure par linéarité et par argument de covergence monotone. On peut aussi supposer, par linéarité, que $\mu_0 = \delta_x$ pour un certain $x \in E$.

D'une part, si $y \in E$, on a $\mathbb{E}_y[G = \mathbb{P}_y(X_0 = x_0, .., X_k = y_k) = \delta_{y,y_0}Q(y_0, y_1)..Q(y_{k-1}, y_k)$.

D'autre part, on a :

$$\begin{aligned}
\mathbb{E}_{\mu_0}[FG \circ \theta_n] &= \mathbb{P}_{\mu_0}(X_0 = x_0, .., X_n = x_n, X_n = y_0, .., X_{n+k} = y_k) \\
&= \delta_{x,x_0}Q(x_0, x_1)..Q(x_{n-1}, x_n)\delta_{x_n,y_0}Q(y_0, y_1)..Q(y_{k-1}, y_k) \\
&= \delta_{x,x_0}Q(x_0, x_1)..Q(x_{n-1}, x_n)\mathbb{E}_{x_n}[G] \\
&= \mathbb{E}_{\mu_0}[F]\mathbb{E}_{x_n}[G] \\
&= \mathbb{E}_{\mu_0}[F\mathbb{E}_{x_n}[G]].
\end{aligned}$$

On a ainsi le résultat. □

On veut à présent généraliser cette propriété de Markov, non pas au temps n, mais à un temps aléatoire.

Définition 2.2.4. Soit $T : \Omega \longrightarrow \overline{\mathbb{N}}$ (où $\overline{\mathbb{N}} = \mathbb{N} \cup \{\infty\}$). On dit que T est **un temps d'arrêt associé à la filtration** $(\mathcal{F}_n)_{n\in\mathbb{N}}$ si : $\forall n \in \mathbb{N}, \{T = n\} \in \mathcal{F}_n$.

On remarque que l'on peut changer l'évènement $\{T = n\}$ de la définition par $\{T \leq n\}$. De plus, l'évènement $\{T = \infty\}$ n'est pas à négliger. On peut écrire $\{T = \infty\} = (\bigcup_{n\in\mathbb{N}}\{T = n\})^c$. On peut aussi remarquer que $\{T \geq n + 1\} \in \mathcal{F}_n$.

Exemple.
- L'application constante $T = k$ est une temps d'arrêt, pour $k \in \mathbb{N}$.
- Si $A \subset E$ et $N_0 \in \mathbb{N}$, on pose $T_A := \inf\{n \geq N_0, X_n \in A\}$, alors T_A est un temps d'arrêt.
- Si S et T sont des temps d'arrêt, alors $T + S$, $T \wedge S$ et $T \vee S$ sont des temps d'arrêt.
- Si (T_k) est une suite de temps d'arrêt, alors $\inf T_k, \sup T_k, \liminf T_k$ et $\limsup T_k$ sont des temps d'arrêt.

Définition 2.2.5. Soit T un temps d'arrêt. On appelle **tribu du passé jusqu'à l'instant** T la tribu

$$\mathcal{F}_T := \{A \in \mathcal{F}, \forall n \in \mathbb{N}, A \cap \{T = n\} \in \mathcal{F}_n\}.$$

Proposition 2.2.5. *Soit T un temps d'arrêt. Alors $\mathcal{F}_T$ est une sous-tribu de $\mathcal{F}$ et $\mathcal{F}_T = \mathcal{F}_n$ si $T = n$. De plus, $\{T = \infty\} \in \mathcal{F}_T$.*

Démonstration. La démonstration est laissée en exercice. □

Proposition 2.2.6. *Soit T et S deux temps d'arrêt. On suppose que $S \leq T$. Alors $\mathcal{F}_S$ est une sous-tribu de $\mathcal{F}_T$.*

Démonstration. Soit $A \in \mathcal{F}_S$ et $n \in \mathbb{N}$. On a $A \cap \{T = n\} = \bigcup_{k=0}^{n}(A \cap \{S = k\}) \cap \{T = n\} \in \mathcal{F}_n$. □

Théorème 2.2.7. *Propriété de Markov forte : Soit T un temps d'arrêt et G une variable aléatoire réelle ou positive, intégrable, définie sur Ω. Alors $\mathbb{E}_{\mu_0}[\mathbb{1}_{T<\infty}G \circ \theta_T|\mathcal{F}_T] = \mathbb{1}_{T<\infty}\mathbb{E}_{X_T}[G]$*

Démonstration. On remarque que X_T est une application définie sur l'ensemble $\mathcal{F}_T$-mesurable $\{T < \infty\}$. Ainsi, l'expression $\mathbb{1}_{T<\infty}\mathbb{E}_{X_T}[G]$ a bien un sens.

Soit $F : \Omega \longrightarrow \mathbb{R}$ une application $\mathcal{F}_T$-mesurable intégrable.

On veut montrer que $\mathbb{E}_{\mu_0}[F\mathbb{1}_{T<\infty}G \circ \theta_T] = \mathbb{E}_{\mu_0}[F\mathbb{1}_{T<\infty}\mathbb{E}_{X_T}[G]]$. On a :

$$\begin{aligned}\mathbb{E}_{\mu_0}[F\mathbb{1}_{T<\infty}G\circ\theta_T] &= \sum_n \mathbb{E}_{\mu_0}[F\mathbb{1}_{T=n}G\circ\theta_T]\\ &= \sum_n \mathbb{E}_{\mu_0}[F\mathbb{1}_{T=n}G\circ\theta_n] \text{ avec } F\mathbb{1}_{T=n}\in\mathcal{F}_n\\ &= \sum_n \mathbb{E}_{\mu_0}[F\mathbb{1}_{T=n}\mathbb{E}_{X_n}[G]] \text{ d'après la propriété de Markov faible}\\ &= \mathbb{E}_{\mu_0}[F\mathbb{1}_{T<\infty}\mathbb{E}_{X_T}[G]]\end{aligned}$$

□

2.3 Classification des états

On conserve les notations du paragraphe précédent. Le but de ce paragraphe est de classifier les états d'une chaîne de Markov.

Définition 2.3.1. Soit $x\in E$. On pose

$$N_x := \sum_{n\geq 0}\mathbb{1}_{X_n=x}.$$

On dit que x est **récurrent** si $N_x=\infty$ presque sûrement pour $\mathbb{P}_x$. Si x n'est pas récurrent, on dit que x est **transient** ou **transitoire**.

Définition 2.3.2. On pose $G: E\times E\longrightarrow\mathbb{R}_+$ définie par $(x,y)\mapsto\mathbb{E}_x[N_y]$. C'est la **matrice potentielle** ou **fonction de** x. Cette fonction compte le nombre de passage en y en partant de l'état x.

Proposition 2.3.1. *Soit $x,y\in E$. Alors $G(x,y)=\sum_{n\geq 0}Q^n(x,y)$.*

Démonstration. On a

$$\begin{aligned}G(x,y) &= \mathbb{E}_x[N_y]\\ &= \mathbb{E}_x[\sum_{n\geq 0}\mathbb{1}_{X_n=x}]\\ &= \sum_{n\geq 0}\mathbb{P}_x[X_n=y]\\ &= \sum_{n\geq 0}Q^n(x,y).\end{aligned}$$

□

Définition 2.3.3. Soit $x\in E$. On pose $T_{x,0}:=0$ et pour $k\geq 1$, $T_{x,k}=T_x:=\inf\{n>T_{x,k-1}, X_n=x\}$, dit **$k$-ème temps de retour en** x. On note $T_{x,1}=T_x$.

Proposition 2.3.2. — *Les $T_{x,k}$ sont des temps d'arrêt*
— *On a $\mathcal{F}_{T_{x,0}}\subset\mathcal{F}_{T_{x,1}}\subset..\subset\mathcal{F}_{T_{x,k}}\subset..$*

Démonstration. Montrons, par exemple, que T_x est un temps d'arrêt. Soit $n\geq 0$. On a

$$\{T_x=n\}=\{X_1=n\}^c\cap..\cap\{X_{n-1}=n\}^c\cap\{X_n=n\}\in\mathcal{F}_n.$$

Pour le second point de la proposition, il suffit d'utiliser la proposition 2.2.6. □

Théorème 2.3.3. *Soit $x\in E$. Alors $G(x,x)=\frac{1}{\mathbb{P}_x(T_x=\infty)}$. De plus,*

$$\begin{aligned}x \text{ est récurrent } &\Leftrightarrow \mathbb{P}_x(T_x<\infty)=1\\ &\Leftrightarrow G(x,x)=\infty\end{aligned}$$

Démonstration. Soit $k \geq 0$. On a :

$$\begin{aligned}\mathbb{P}_x(N_x \geq k+1) &= \mathbb{E}_x[\mathbb{1}_{T_x<\infty}\mathbb{1}_{N_x\geq k} \circ \theta_{T_x}] \\ &= \mathbb{E}_x[\mathbb{1}_{T_x<\infty}\mathbb{E}_{X_{T_x}}[\mathbb{1}_{N_x\geq k}]] \text{ d'après la propriété de Markov forte et car } X_{T_x} = x \\ &= \mathbb{E}_x[\mathbb{1}_{T_x<\infty}\mathbb{P}_x(N_x \geq k)] \\ &= \mathbb{P}_x(T_x < \infty)\mathbb{P}_x(N_x \geq k)\end{aligned}$$

Ainsi, $\mathbb{P}_x(N_x \geq k) = \mathbb{P}_x(T_x < \infty)^{k-1}$ car $\mathbb{P}_x(N_x \geq 1) = 1$. De plus :

$$\begin{aligned}G(x,x) &= \mathbb{E}_x[N_x] \\ &= \sum_{k\geq 0} \mathbb{P}_x(N_x \geq k) \\ &= \frac{1}{1-\mathbb{P}_x(T_x<\infty)} \\ &= \frac{1}{\mathbb{P}_x(T_x=\infty)}\end{aligned}$$

En utilisant le fait que $\mathbb{P}_x(N_x \geq k) = \mathbb{P}_x(T_x < \infty)^{k-1}$, et l'égalité qui précède, on a alors les équivalences. □

Proposition 2.3.4. *Soient $x, y \in E$ avec $x \neq y$, alors $G(x,y) = \mathbb{P}_x(T_y < \infty)G(y,y)$*

Démonstration. On a :

$$\begin{aligned}G(x,y) &= \mathbb{E}_x[N_y] \\ &= \mathbb{E}_x[\mathbb{1}_{T_y<\infty}N_y \circ \theta_{T_y}] \\ &= \mathbb{P}_x(T_y < \infty)\mathbb{E}_y[N_y] \text{ d'après la propriété de Markov forte}\end{aligned}$$

□

Exemple. Considérons la marche aléatoire sur le groupe $\mathbb{Z}^d$ associée au système de générateurs $\{\sum_{i=1}^{d} \epsilon_i e_i\}$ où $\epsilon_i \in \{-1, 1\}$. On a $Q^{2k+1}(0,0) = 0$ et $Q^{2k}(0,0) = (2^{-2k}\binom{k}{2k})^d$. On a donc :

$$\begin{aligned}G(0,0) &= \sum_{k\geq 0} Q_{2k}(0,0) \\ &= \sum_{k\geq 0} (2^{-2k}\binom{2k}{k})^d\end{aligned}$$

Par ailleurs, on a :

$$\begin{aligned}2^{-2k}\binom{2k}{k} &\sim \frac{1}{2^{2k}} \frac{(\frac{2k}{e})^{2k}\sqrt{4\pi k}}{((\frac{k}{e})^k\sqrt{2\pi k})^2} \\ &\sim \sqrt{\frac{1}{\pi k}}\end{aligned}$$

Ainsi, si $d = 1, 2$, alors tous les points sont récurrents, et si $d \geq 3$, alors tous les points sont transients.

On note R l'ensemble des états récurrents.

Proposition 2.3.5. *Soient $x \in R$ et $y \in E$. On suppose que $G(x,y) > 0$. Alors $y \in R$, $\mathbb{P}_y(T_x < \infty) = 1$ et $G(y,x) > 0$. En particulier, si $x \in R$ et $y \in E - R$, alors $G(x,y) = 0$.*

Démonstration. On a

$$\begin{aligned}
0 &= \mathbb{P}_x(N_x < \infty) \\
&\geq \mathbb{P}_x(T_y < \infty, T_x \circ \theta_{T_y} = \infty) \\
&= \mathbb{P}_x(\mathbb{1}_{T_y<\infty}\mathbb{1}_{T_x=\infty} \circ \theta_{T_y}) \\
&= \mathbb{P}_x(\mathbb{1}_{T_y<\infty}\mathbb{P}_y(T_x = \infty)) \text{ d'après la propriété de Markov forte} \\
&= \mathbb{P}_x(T_y < \infty)\mathbb{P}_y(T_x = \infty)
\end{aligned}$$

Comme $G(x,y) > 0$ et x est récurrent, $\mathbb{P}_x(T_y < \infty) > 0$, donc $\mathbb{P}_y(T_x = \infty) = 0$, donc $\mathbb{P}_y(T_x < \infty) = 1$ et $G(y,x) = G(x,x) > 0$.

Considérons à présent $n_1, n_2 \geq 1$ tels que $Q^{n_1}(x,y) > 0$ et $Q^{n_2}(y,x) > 0$. Alors,

$$\forall p \geq 0, Q^{n_1+n_2+p}(y,y) \geq Q^{n_2}(y,x)Q^p(x,x)Q^{n_1}(x,y)$$

. Ainsi,

$$\begin{aligned}
G(y,y) &\geq \sum_{p\geq 0} Q^{n_1+n_2+p}(y,y) \\
&\geq Q^{n_2}(y,x)(\sum_{p\geq 0} Q^p(x,x))Q^{n_1}(x,y) \\
&= \infty.
\end{aligned}$$

Ceci montre que y est récurrent. □

Théorème 2.3.6. *Classification des états*

On peut définir une partition $R = \bigsqcup_{i\in I} R_i$ telle que

- *si $x \in R_i$ et $y \in E$, alors $\mathbb{P}_x(N_y = \infty) = 1$ si $y \in R_i$ et $\mathbb{P}_x(N_y = 0) = 1$ si $y \notin R_i$.*
- *si $x \in E - R$ et si l'on pose $T := \inf\{n \geq 0, X_n \in R\}$, alors ou $\mathbb{P}_x(T = \infty) = 1$ et, dans ce cas, $\forall y \in E, \mathbb{P}_x(N_y < \infty) = 1$; ou $\mathbb{P}_x(T < \infty) > 0$ et, dans ce cas, $\exists j \in I, \mathbb{P}_x(\forall n \geq T, X_n \in R_j) > 0$.*

*Les R_i sont appelées **classes de récurrence**.*

Démonstration. Soit $x, y \in R$, on pose $x \sim y$ si $G(x,y) > 0$ et $G(y,x) > 0$. D'après la proposition précédente, cela définit une relation d'équivalence sur R, ce qui induit une partition $R = \bigsqcup_{i\in I} R_i$.

Soit $x \in R_i$. D'après ce qui précède, si $y \notin R_i$, on a $G(x,y) = 0$, donc $\mathbb{P}_x(N_y = 0) = 1$. Si $y \in R_i, \mathbb{P}_x(T_y < \infty) = 1$ d'après ce qui précède, et on a

$$\begin{aligned}
\mathbb{P}_x(N_y = \infty) &= \mathbb{E}_x(\mathbb{1}_{T_y<\infty}\mathbb{1}_{N_y=\infty} \circ \theta_{T_y}) \\
&= \mathbb{P}_x(T_y < \infty)\mathbb{P}_y(N_y = \infty) \text{ d'après la propriété de Markov forte} \\
&= 1.
\end{aligned}$$

Soit à présent $x \in E - R$. On suppose dans un premier temps $\mathbb{P}_x(T = \infty) = 1$. On voit que T est un temps d'arrêt, car $T = \inf_{x\in R} T_x$. De plus :

$$\begin{aligned}
\mathbb{P}_x(N_y = \infty) &= \mathbb{P}_x(\mathbb{1}_{T<\infty}\mathbb{1}_{N_y=\infty} \circ \theta_T) \\
&= \mathbb{P}_x(T < \infty)\mathbb{P}_{X_T}(N_y = \infty) \text{ d'après le propriété de Markov forte} \\
&= 0.
\end{aligned}$$

Ainsi, $\mathbb{P}_x(N_y < \infty) = 1$.

Supposons à présent $\mathbb{P}_x(T < \infty) > 0$. On a alors

$$\begin{aligned}
0 < \mathbb{P}_x(T < \infty) &= \mathbb{P}_x(\inf_{y\in R} T_y < \infty) \\
&\leq \sum_{y\in R} \mathbb{P}_x(T_y < \infty).
\end{aligned}$$

Soit $y \in R$ tel que $\mathbb{P}_x(T_y < \infty) > 0$. Soit $j \in I$ tel que $y \in R_j$. Alors $\mathbb{P}_x(X_T \in R_j) > 0$. Soit enfin $n \geq T$, on a

$$\begin{aligned}\mathbb{P}_x(X_{n+1} \in R_j) &= \mathbb{P}_x(\mathbb{1}_{T<\infty}\mathbb{1}_{X_n \in R_j} \circ \theta_T) \\ &= \mathbb{P}_x(T < \infty)\mathbb{P}_{X_T}(X_n \in R_j) \text{ d'après la propriété de Markov forte.}\end{aligned}$$

On a alors le résultat. □

Corollaire 2.3.7. *On suppose que le chaîne est irréductible.*

— *Ou bien tous les états sont récurrents, alors il n'existe qu'une seule clsse de récurrence et*

$$\forall x \in E, \mathbb{P}_x(\forall y \in E, N_y = \infty) = 1;$$

ou bien tous les états sont transients et

$$\forall x \in E, \mathbb{P}_x(\forall y \in E, N_y < \infty) = 1.$$

— *Si E est fini, on est dans le premier cas.*

Démonstration. Le premier point est conséquence de ce qui précède et du fait qu'une union dénombrable de parties négligeables est aussi négligeable. Démontrons le deuxième point, et supposons donc E fini. On suppose par l'absurde que tous les états sont transients, et on considère $x \in E$. Alors, d'après ce qui précède, $\mathbb{P}_x(\forall y \in E, N_y < \infty) = 1$, donc $\mathbb{P}_x(\sum_{y\in E} N_y < \infty) = 1$ car E est fini. Par ailleurs, on a

$$\begin{aligned}\sum_{y\in E} N_y &= \sum_{y\in E}\sum_{n\geq 0} \mathbb{1}_{X_n=y} \\ &= \sum_{n\geq 0}\sum_{y\in E} \mathbb{1}_{X_n=y} \\ &= \infty \text{ , ce qui est absurde.}\end{aligned}$$

□

Définition 2.3.4. Lorsque l'on est dans le premier cas du corollaire précédent, on dit que la chaîne est **récurrente irréductible**.

2.4 Chaînes de Markov et mesures invariantes

On conserve dans ce paragraphe les notations des paragraphes précédents. Nous allons dans un premier temps donner une condition suffisante pour qu'il existe une mesure invariante.

Théorème 2.4.1. *On suppose $R \neq \emptyset$ et on considère $x \in R$. Alors il existe une mesure μ invariante non dégénérée, donnée par*

$$\mu(y) = \mathbb{E}_x[\sum_{k=0}^{T_x-1} \mathbb{1}_{X_k=y}].$$

De plus, le support de μ est la classe de récurrence de x.

Démonstration. Comme x est récurrent, on a

$$\mathbb{P}_x(T_x < \infty) = 1,$$

donc la somme est bien définie. Soit $y \in E$. Remarquons que

$$\sum_{k=0}^{T_x-1} \mathbb{1}_{X_k=y} = \sum_{k=1}^{T_x} \mathbb{1}_{X_k=y}.$$

En effet, si $y \neq x$ et que l'on part de l'état x, on ne peut pas se trouver en y au temps 0 ni au temps T_x. Si $y = x$, on a

$$\mathbb{P}_x(X_0 = x) = \mathbb{P}_x(X_{T_x} = x) = 1.$$

Montrons que μ est une mesure Q-invariante. Cela découle du calcul suivant.

$$\begin{aligned}
\mu(y) &= \mathbb{E}_x[\sum_{k=0}^{T_x-1} \mathbb{1}_{X_k=y}] \\
&= \mathbb{E}_x[\sum_{k=1}^{T_x} \mathbb{1}_{X_k=y}] \\
&= \sum_{z\in E} \mathbb{E}_x[\sum_{k=1}^{T_x} \mathbb{1}_{X_k=y, X_{k-1}=z}] \\
&= \sum_{z\in E}\sum_{k\geq 1} \mathbb{E}_x[\mathbb{1}_{T_x\geq k}\mathbb{1}_{X_{k-1}=z}\mathbb{1}_{X_1=y}\circ\theta_{k-1}] \text{ où } \mathbb{1}_{T_x\geq k}\mathbb{1}_{X_{k-1}=z} \in \mathcal{F}_{k-1} \\
&= \sum_{z\in E}\sum_{k\geq 1} \mathbb{E}_x[\mathbb{1}_{T_x\geq k}\mathbb{1}_{X_{k-1}=z}\mathbb{E}_{X_{k-1}}[\mathbb{1}_{X_1}=y]] \text{ d'après la propriété de Markov faible} \\
&= \sum_{z\in E} \mathbb{E}_x[\sum_{k=0}^{T_x-1} \mathbb{1}_{X_k=z}]Q(z,y) \text{ car } \mathbb{1}_{X_{k-1}=z}\mathbb{E}_{X_{k-1}}[\mathbb{1}_{X_1}=y] = \mathbb{1}_{X_{k-1}=z}\mathbb{P}_z(X_1=y) = \mathbb{1}_{X_{k-1}=z}Q(z,y) \\
&= \sum_{z\in E} \mu(z)Q(z,y).
\end{aligned}$$

Montrons à présent que $\mu(y) < \infty$. Remarquons que

$$\begin{aligned}
1 &= \mu(x) \\
&= \mu Q^n(x) \\
&= \sum_{z\in E} \mu(z)Q^n(z,x).
\end{aligned}$$

Comme x est récurrent, si $G(x,y) > 0$, alors $G(y,x) > 0$, donc $\exists n \in \mathbb{N}, Q^n(y,x) > 0$, ce qui montre que $\mu(y) < \infty$ d'après ce qui précède. Si $G(x,y) = \mathbb{E}_x[N_y] = 0$, alors $\mu(y) = 0$. Montrons enfin le dernier point. Si y est dans la même classe de récurrence que x, alors on peut considérer $m \in \mathbb{N}$ tel que $Q^m(x,y) > 0$. Notons que $\mu(x) = 1$. On a alors

$$\begin{aligned}
\mu(y) &= \sum_{z\in E} \mu(z)Q_m(z,y) \\
&\geq Q^m(x,y) \\
&> 0.
\end{aligned}$$

□

Théorème 2.4.2. *On suppose ici que la chaîne est récurrente irréductible. Alors il existe une unique mesure invariante à constante positive non nulle près.*

Démonstration. Soit $x \in E = R$. On note π_x la mesure définie pour x dans le théorème précédent. Soit μ une autre mesure invariante. Comme la chaîne est irréductible, la mesure est non nulle en chaque point. On peut donc supposer que $\mu(x) = 1$. On va montrer que $\mu = \pi_x$, et donc dans un premier temps que $\mu \geq \pi_x$, puis $\pi_x \geq \mu$. Soit $y \in E$. On a

$$\begin{aligned}
\mu(y) &= \sum_{z_1\in E} \mu(z_1)Q(z_1,y) \\
&= Q(x,y) + \sum_{z_1\in E-\{x\}} \mu(z_1)Q(z_1,y) \\
&= Q(x,y) + \sum_{\substack{z_1\neq x \\ z_2\in E}} \mu(z_2)Q(z_2,z_1)Q(z_1,y) \\
&= Q(x,y) + \sum_{z_1\neq x} Q(x,z_1)Q(z_1,y) + \sum_{\substack{z_1\neq x \\ z_2\neq x}} \mu(z_2)Q(z_2,z_1)Q(z_1,y).
\end{aligned}$$

On remarque que

$$Q(x,y) + \sum_{z_1 \neq x} Q(x,z_1)Q(z_1,y) = \mathbb{E}_x[\sum_{k=0}^{2\wedge(T_x-1)} \mathbb{1}_{X_k=y}].$$

Ainsi, par récurrence, on montre que

$$\mu(y) = \mathbb{E}_x[\sum_{k=0}^{p\wedge(T_x-1)} \mathbb{1}_{X_k=y}] + \sum_{\substack{z_i \neq x \\ 1\leq i\leq p}} \mu(z_p)Q(z_p,z_{p-1})..Q(z_1,y).$$

Par suite, comme la chaîne est récurrente, $\mathbb{P}_x(T_x < \infty) = 1$, donc $\mu(y) \geq \pi_x(y)$.
Réciproquement, on a :

$$\begin{aligned} 1 &= \mu(x) \\ &= \sum_{z\in E} \mu(z)Q(z,x) \\ &\geq \sum_{z\in E} \pi_x(z)Q(z,x) \\ &= \pi_x(x) \\ &= 1. \end{aligned}$$

Ainsi, l'inégalité est une égalité, donc $\forall z, \mu(z) = \pi_x(z)$, et donc $\mu = \pi_x$. □

Exemple. Considérons la marche aléatoire sur $\mathbb{Z}^2$, on sait que la chaîne est récurrente irréductible, alors $\mu := \sum_{x\in\mathbb{Z}^2} \delta_x$ est l'unique mesure invariante telle que $\mu(0) = 1$.

Corollaire 2.4.3. *On suppose que la chaîne est récurrente irréductible. On considère μ la mesure (donnée à une constante près) du théorème précédent. Alors :*

- *Ou bien $\mu(E) < \infty$, alors il existe une unique mesure de probabilité invariante, et dans ce cas on a $\forall x, y \in E, \mathbb{E}_y[T_x] < \infty$ et $\mu(x) = \frac{1}{\mathbb{E}_x[T_x]}$*
- *Ou bien $\mu(E) = \infty$, et dans ce cas $\forall x \in E, \mathbb{E}_x[T_x] = \infty$.*

*Dans le premier cas, on dit que la chaîne est **récurrente positive**, et dans le second cas, que la chaîne est **récurrente nulle**. On remarque que si, de plus, E est fini, alors la chaine est récurrente positive.*

Démonstration. Soit $x \in E$, on note π_x la mesure invariante définie en x utilisée dans les théorèmes précédents. On a :

$$\begin{aligned} \pi_x(E) &= \sum_{y\in E} \pi_x(y) \\ &= \sum_{y\in E} \mathbb{E}_x[\sum_{k=0}^{T_x-1} \mathbb{1}_{X_k=y}] \\ &= \mathbb{E}_x[\sum_{k=0}^{T_x-1} 1] \\ &= \mathbb{E}_x[T_x]. \end{aligned}$$

Ceci montre déjà le deuxième point. Pour le premier point, on pose $\mu := \frac{\pi_x}{\pi_x(E)}$, alors d'après le théorème précédent, μ est l'unique mesure de probabilité Q-invariante sur E, et l'on a d'après ce qui précède $\mu(x) = \frac{1}{\mathbb{E}_x[T_x]}$. Enfin, si $y \in E$, on a $\mathbb{E}_y[T_x] \leq \mathbb{E}_x[T_x] < \infty$. □

Exemple. Considérons la marche aléatoire du cavalier sur l'échiquier, la chaîne est récurrente positive, et la mesure de probabilité invariante est donnée par

$$\pi(x) = \frac{\deg(x)}{\sum_y \deg(y)} = \frac{\deg(x)}{336}.$$

On note a la case en bas à gauche de l'échiquier, on a $\deg(a) = 2$, donc d'après ce qui précède, on a $\mathbb{E}_a[T_a] = \frac{336}{2} = 168$: le temps moyen de premier retour en a en partant de a est 168 coups.

Théorème 2.4.4. *On suppose que Q est irréductible et qu'il existe une mesure Q-invariante finie, alors la chaîne est récurrente, et donc récurrente positive.*

Démonstration. Il suffit de montrer que le chaîne est récurrente. On note μ une mesure finie Q-invariante, et on considère $y \in E$ tel que $\mu(y) > 0$. Comme la chaîne est irréductible, il suffit de montrer que y est récurrent, c'est-à-dire que $G(y,y) = \infty$. Soit $x \in E$. On a

$$\sum_{n\geq 0} Q^n(x,y) = G(x,y) \leq G(y,y)$$

car $G(x,y) = \mathbb{P}_x(T_y < \infty)G(y,y)$.

Ainsi,

$$\sum_{n\geq 0} \mu(x)Q^n(x,y) \leq \mu(x)G(y,y).$$

En sommant à présent sur x, on a

$$\begin{aligned}\sum_{n\geq 0} \mu(y) &= \sum_{n\geq 0}\sum_{x\in E} \mu(x)Q^n(x,y) \\ &\leq (\sum_{x\in E}\mu(x))G(y,y).\end{aligned}$$

Ainsi, comme la mesure est finie, $G(y,y) = \infty$, d'où le résultat. □

Exemple. Considérons la chaîne suivante, dite "de vie ou de mort". Soit $p \in]0,1[$, $q := 1-p$. On suppose $E = \mathbb{N}, Q(0,1) = 1, Q(k,k+1) = p, Q(k,k-1) = q$ pour $k \geq 1$. La chaîne est alors irréductible et non apériodique. On pose $\mu(0) := q$ et $\mu(k) := (\frac{p}{q})^{k-1}$ pour $k \geq 1$, alors cette mesure est invariante. On a trois cas :

- si $p < q$, alors $\mu(\mathbb{N}) < \infty$, donc la chaîne est récurrente, donc récurrente positive, et μ est l'unique mesure invariante. On a alors $\mathbb{E}_0[T_0] = \frac{1}{q}$ et $\mathbb{E}_k[T_k] = (\frac{q}{p})^{k-1}$ pour $k \geq 1$.
- si $p = q = \frac{1}{2}$, alors $X_n = |Z_n|$ où (Z_n) est la marche aléatoire simple sur $\mathbb{Z}$, donc la chaîne est récurrente, donc récurrente nulle.
- si $p > q$, on montre que la chaîne est transiente.

Intéressons-nous à présent au comportement asymptotique d'une mesure invariante.

Théorème 2.4.5. *On suppose que le chaîne est récurrente irréductible, soit μ une mesure invariante, $f, g : E \longrightarrow [0, +\infty]$ mesurables, avec*

$$\int f d\mu < \infty,\ 0 < \int g d\mu < \infty.$$

Alors,

$$\forall x \in E, \mathbb{P}_x(\lim_n \frac{\sum_{k=0}^n f(X_k)}{\sum_{k=0}^n g(X_k)} = \frac{\int f d\mu}{\int g d\mu}) = 1.$$

Démonstration. Soit $x \in E$. Pour simplifier les notations, on pose $T_n := T_{x,n}$.

Remarquon que $\mathbb{P}_x(T_n < \infty) = 1$. En effet, soit $k \geq 0$, on a

$$\begin{aligned}\mathbb{P}_x(N_x \geq k+n) &= \mathbb{E}_x[\mathbb{1}_{T_n<\infty}\mathbb{1}_{N_x\geq x} \circ \theta_n] \\ &= \mathbb{E}_x[\mathbb{1}_{T_n<\infty}\mathbb{E}_{X_{T_n}}[\mathbb{1}_{N_x} \geq k]] \text{ par propriété de Markov faible} \\ &= \mathbb{P}_x(T_n < \infty)\mathbb{P}_x(N_x \geq k).\end{aligned}$$

Comme x est récurrent, $\mathbb{P}_x(N_x = \infty) = 1$, donc $\mathbb{P}_x(T_n < \infty) = 1$.

On pose alors $Z_k(f) := \sum_{n=T_k}^{T_{k+1}-1} f(X_n)$. Montrons que la suite $(Z_k(f))$ est consituée de variables indépendantes identiquement distribuées lorsque l'on munit Ω de la probabilité $\mathbb{P}_x$.

Soient $g_0, g_1, ..$ des fonctions mesurables bornées sur $\mathbb{R}_+$ à valeur dans $\mathbb{R}_+$. Il suffit de montrer que

$$\forall k \geq 0, \mathbb{E}_x[\prod_{i=0}^k g_i(Z_i(f))] = \prod_{i=0}^k \mathbb{E}_x[g_i(Z_0(f))].$$

Montrons le par récurrence sur k. On suppose le résultat vrai au rang $k-1$. Les variables $Z_0(f)$, .., $Z_{k-1}(f)$ sont $\mathcal{F}_{T_k}$-mesurables. En effet, si $n \leq k-1$, alors $f(X_n)$ est $\mathcal{F}_n$-mesurable, donc $\mathcal{F}_k$-mesurable. Soit à présent B un borélien de $\mathbb{R}_+$:

— si $n = k-1$ et $p \in \mathbb{N}$, on a

$$Z_n(f)^{-1}(B) \cap \{T_k = p\} = \bigcup_{i<p} (\{T_k = p\} \cap \{T_n = i\} \cap (\sum_{l=i}^{p-1} f(X_k))^{-1}(B)) \in \mathcal{F}_p.$$

— si $n < k-1$ et $p \in \mathbb{N}$, on a

$$Z_n(f)^{-1}(B) \cap \{T_k = p\} = \bigcup_{i<j<p} (\{T_k = p\} \cap \{T_n = i\} \cap \{T_{n+1} = j\} \cap (\sum_{l=i}^{j} f(X_l))^{-1}(B)) \in \mathcal{F}_p.$$

Ainsi, si $n \leq k-1, Z_n(f)$ est $\mathcal{F}_{T_k}$-mesurable.

On remarque à présent que $Z_k(f) = Z_0(f) \circ \theta_{T_k}$, donc, d'après la propriété forte de Markov, on peut écrire

$$\begin{aligned}
\mathbb{E}_x[\prod_{i=0}^{k} g_i(Z_i(f))] &= \mathbb{E}_x[(\prod_{i=0}^{k-1} g_i(Z_i(f)))g_k(Z_0(f) \circ \theta_{T_k})] \\
&= \mathbb{E}_x[\prod_{i=0}^{k-1} g_i(Z_i(f))]\mathbb{E}_x[g_k(Z_0(f))] \\
&= \prod_{i=0}^{k} \mathbb{E}_x[g_i(Z_0(f))] \text{ par hypothèse de récurrence .}
\end{aligned}$$

Déterminons à présent leure espérance :

$$\begin{aligned}
\mathbb{E}_x[Z_0(f)] &= \mathbb{E}_x[\sum_{k=0}^{T_x-1} \sum_{y \in E} f(y)\mathbb{1}_{X_k=y}] \\
&= \sum_{y \in E} f(y)\pi_x(y) \\
&= \frac{\int_E f d\mu}{\mu(x)}.
\end{aligned}$$

Ainsi, $(Z_k(f))$ est une suite de variables aléatoires indépendantes identiquement distribuées, donc d'après la loi forte des grands nombres,

$$\frac{1}{n}\sum_{k=0}^{n-1} Z_k(f) \underset{n\to\infty}{\longrightarrow} \frac{\int_E f d\mu}{\mu(x)},$$

où la convergence est presque sûre (pour $\mathbb{P}_x$).

On pose à présent

$$N_x(n) := \sum_{k=1} n\mathbb{1}_{X_k=x}.$$

On a $T_{N_x(n)} \leq n < T_{N_x(n)+1}$. On suppose $N_x(n) \geq 1$. On a alors

$$\frac{\sum_{k=0}^{T_{N_x(n)}-1} f(X_k)}{N_x(n)} \leq \frac{\sum_{k=0}^{n} f(X_k)}{N_x(n)} \leq \frac{\sum_{k=0}^{T_{N_x(n)+1}-1} f(X_k)}{N_x(n)}$$

$$\text{donc } \frac{\sum_{j=0}^{N_x(n)-1} Z_j(f)}{N_x(n)} \leq \frac{\sum_{k=0}^{n} f(X_k)}{N_x(n)} \leq \frac{\sum_{j=0}^{N_x(n)} Z_j(f)}{N_x(n)}$$

Ainsi,

$$\frac{1}{N_x(n)}\sum_{k=0}^{n} f(X_k) \underset{n\to\infty}{\longrightarrow} \frac{\int_E f d\mu}{\mu(x)},$$

où la convergence est presque sûre (pour $\mathbb{P}_x$). De même,

$$\frac{1}{N_x(n)}\sum_{k=0}^{n} g(X_k) \underset{n\to\infty}{\longrightarrow} \frac{\int_E g d\mu}{\mu(x)},$$

où la convergence est presque sûre (pour $\mathbb{P}_x$). Comme

$$\int_E g d\mu > 0,$$

on a

$$\sum_{k=0}^{n} g(X_k) > 0$$

pour n assez grand, et presque sûrement (pour $\mathbb{P}_x$), puis on a bien

$$\mathbb{P}_x(\lim_n \frac{\sum_{k=0}^n f(X_k)}{\sum_{k=0}^n g(X_k)} = \frac{\int f d\mu}{\int g d\mu}) = 1.$$

□

Pour finir ce paragraphe, intéressons-nous à la problématique suivante : quelles hypothèses sur la chaîne de Markov peut-on faire pour que, partant d'une mesure de probabilité initiale μ_0, la suite (μ_n) converge en loi vers une mesure de probabilité Q-invariante ? Pour répondre à cette question, nous allons définir sur l'ensemble des mesures de probabilité sur E une distance qui va traduire la notion de convergence en loi.

Proposition 2.4.6. *Soient μ et ν deux mesure de probabilité sur E. Alors,*

$$\sup_{A\subset E} |\mu(A) - \nu(A)| = \frac{1}{2}\sum_{x\in E} |\mu(x) - \nu(x)|.$$

Démonstration. Soit $A \subset E$, on a $\mu(A) + \mu(A^c) = 1 = \nu(A) + \nu(A^c)$, donc $\mu(A) - \nu(A) = \nu(A^c) - \mu(A^c)$, on a donc

$$\begin{aligned} |\mu(A) - \nu(A)| &= \frac{1}{2}(|\mu(A) - \nu(A)| + |\mu(A^c) - \nu(A^c)|) \\ &\leq \frac{1}{2}\sum_{x\in E} |\mu(x) - \nu(x)|. \end{aligned}$$

Réciproquement, on pose $A := \{x \in E, \mu(x) \geq \nu(x)\}$. On a alors

$$\begin{aligned} |\mu(A) - \nu(A)| &= \frac{1}{2}(|\sum_{x\in A} \mu(x) - \nu(x)| + |\sum_{x\in A^c} \nu(x) - \mu(x)|) \\ &= \frac{1}{2}\sum_{x\in A} |\mu(x) - \nu(x)|. \end{aligned}$$

□

Corollaire 2.4.7. *On a*

$$\begin{aligned} \sup_{A\subset E} |\mu(A) - \nu(A)| &= \max_{A\subset E} |\mu(A) - \nu(A)| \\ &= \sum_{\substack{x\in E \\ \mu(x)\geq\nu(x)}} \mu(x) - \nu(x). \end{aligned}$$

Définition 2.4.1. On pose

$$d(\mu,\nu) := \sup_{A\subset E} |\mu(A) - \nu(A)|$$

. On appelle cette quantité **distance en variation totale de μ et ν**. En utilisant les différentes définitions, il est facile de voir que l'on a bien une distance sur l'ensemble des mesures de probabilité sur E.

Proposition 2.4.8. *La topologie induite par la distance en variation totale correspond à la convergence en loi.*

Démonstration. On considère des mesures de probabilité μ_n et μ sur E.

On suppose que $(\mu_n(f))$ converge vers $\mu(f)$ pour toute fonction $f : E \longrightarrow \mathbb{R}$ bornée. Si l'on choisit f comme étant la fonction caractéristique en un point $y \in E$, on voit que $\forall y \in E, \lim_n \mu_n(y) = \mu(y)$. Soit $\epsilon > 0$. Comme μ est une mesure finie, il existe $A_\epsilon \subset E$ un ensemble fini tel que $\mu(A_\epsilon^c) \leq \epsilon$. Comme A_ϵ est fini, d'après ce qui précède, on a pour n assez grand

$$\sum_{x \in A_\epsilon} |\mu_n(x) - \mu(x)| \leq \epsilon.$$

Par ailleurs, en considérant la fonction caractéristique de A_ϵ^c, on a pour n assez grand

$$\mu_n(A_\epsilon^c) \leq 2\epsilon.$$

Ainsi, pour n assez grand, on a

$$\begin{aligned} d(\mu_n, \mu) &\leq \frac{1}{2}\Big(\sum_{x \in A_\epsilon} |\mu_n(x) - \mu(x)| + \sum_{x \in A_\epsilon^c} \mu_n(x) + \mu(x)\Big) \\ &\leq \frac{1}{2}\epsilon + \mu(A_\epsilon^c) + \mu_n(A_\epsilon^c) \\ &\leq \frac{1}{2}\epsilon + 3\epsilon. \end{aligned}$$

On a donc (μ_n) qui converge vers μ pour la distance en variation totale.

Réciproquement, on suppose que (μ_n) converge vers μ pour la distance en variation totale, et soit $f : E \longrightarrow \mathbb{R}$ une fonction bornée. On a alors :

$$\begin{aligned} |\mu_n(f) - \mu(f)| &\leq \sum_{x \in E} |\mu_n(x) - \mu(x)||f(x)| \\ &\leq 2\|f\|_\infty d(\mu_n, \mu). \end{aligned}$$

Ainsi, $(\mu_n(f))$ converge vers $\mu(f)$, et on a le résultat. □

Définition 2.4.2. Soient μ et ν deux mesures de proababilité sur un espace de probabilité Ω. On appelle **couplage de μ et ν** le donnée d'une paire de variables aléatoires (X, Y) à valeur dans $\Omega \times \Omega$ telle que la marginale de X est μ et la marginale de Y est ν

Exemple. Si μ a pour loi la densité $f(x)dx$ et ν a pour loi la densité $g(y)dy$ alors (X, Y), de loi la densité $f(x)g(y)dxdy$ est un couplage de μ et ν.

Exemple. On peut considérer les couplages de trois Bernoulli suivants :
- si $X_i \sim \mathcal{B}(\frac{1}{2})$, alors (X_1, X_2, X_3) en est un,
- si $X_1 \sim \mathcal{B}(\frac{1}{2})$, alors (X_1, X_1, X_1) en est un autre,
- si $X_1, X_2 \sim \mathcal{B}(\frac{1}{2})$, avec X_1 et X_2 indépendants, alors (X_1, X_2, X_1X_2) en est encore un autre.

Exemple. On peut considérer les couplages de deux Gaussiennes suivants : soit X, Y deux gaussiennes indépendantes identiquement distribuées, et $a \in [-1, 1]$, alors $(X, \alpha X + \sqrt{1 - \alpha^2}Y)$ est un couplage de deux Gaussiennes.

Proposition 2.4.9. *Soient μ, ν deux mesures de probabilité sur E. Alors,*

$$d(\mu, \nu) = \min_{(X,Y) \text{ couplage de } \mu \text{ et } \nu} \mathbb{P}(X \neq Y).$$

Démonstration. Soit π un couplage de μ et ν et $A \in E$ un évènement qui réalise $d(\mu, \nu)$ dans la définition de la distance. On a

$$\begin{aligned} d(\mu, \nu) &= \mu(A) - \nu(A) \\ &= \mathbb{P}(X \in A) - \mathbb{P}(Y \in A) \\ &\leq \mathbb{P}(X \in A, y \notin A) \\ &\leq \mathbb{P}(X \neq Y) \end{aligned}$$

Ainsi, on a

$$d(\mu,\nu) \leq \min_{(X,Y) \text{ couplage de } \mu \text{ et } \nu} \mathbb{P}(X \neq Y).$$

Réciproquement, on pose

$$p := \sum_{x\in E} \mu(x) \wedge \nu(x).$$

On a

$$\begin{aligned} p &= \sum_{\substack{x\in E \\ \mu(x)\leq\nu(x)}} \mu(x) + \sum_{\substack{x\in E \\ \nu(x)\leq\mu(x)}} \nu(x) \\ &= \sum_{x\in E} \mu(x) - \sum_{\substack{x\in E \\ \nu(x)\leq\mu(x)}} (\mu(x)-\nu(x)) \\ &= 1 - d(\mu,\nu). \end{aligned}$$

On construit alors le couplage (X,Y) de la façon suivante : avec probabilité p, on choisit aléatoirement $X = Y = x$ suivant la loi $\frac{\mu(x)\wedge\nu(x)}{p}$, et avec probabilité $1-p$, on choisit aléatoirement $X = x\frac{\mu(x)-\nu(x)}{1-p}$ si $\mu(x) < \nu(x)$, et $Y = x\frac{\nu(x)-\mu(x)}{1-p}$ si $\nu(x) > \mu(x)$. Vérifions que l'on obtient un couplage de μ et ν. Soit $x \in E$, alors,

$$\begin{aligned} \mathbb{P}(X = x) &= p\frac{\mu(x)\wedge\nu(x)}{p} + (1-p)\frac{\mu(x)-\nu(x)}{1-p}\mathbb{1}_{\mu>\nu} \\ &= \mu(x). \end{aligned}$$

De même, on a $\mathbb{P}(Y = y) = \nu(y)$. Finalement, on a $\mathbb{P}(X \neq Y) = 1 - p = d(\mu,\nu)$ ce qui montre le résultat.

□

Nous arrivons enfin au résultat qui nous intéresse :

Théorème 2.4.10. *Soit (X_n) une chaîne de Markov irréductible récurrente positive apériodique, on note μ_0 la mesure initiale. Alors (μ_n) converge en loi vers π où π est l'unique mesure de probabilité Q-invariante.*

Démonstration. On suppose dans un premier temps le résultat vrai pour les $\mu_0 = \delta_x$, avec $x \in E$ fixé. Dans ce cas, pour μ_0 donné, on peut écrire $E = \bigcup E_k$, union croissante, où E_k est fini. On a alors

$$\forall k \in \mathbb{N}, d(Q^n\mu_0, Q^n\pi) \leq \frac{1}{2}\sum_{x\in E_k} \mu_0(x) d(Q^n\delta_x, Q^n\pi) + \frac{1}{2}\mu_0(E_k^c),$$

donc $\limsup_n d(Q^n\mu_0, Q^n\pi) \leq \frac{1}{2}\mu_0(E_k^c)$ par hypothèse, puis on a bien (μ_n) qui converge vers π. Ainsi, on suppose par la suite que $\mu_0 = \delta_x$ pour x fixé. L'idée de la démonstration est de trouver un couplage $(\tilde{X_n}, \tilde{Y_n})$ efficace, où (X_n) est une chaîne de Markov de matrice de transition Q partant de δ_x, et (Y_n) partant de π. Pour réaliser un tel couplage, on considère dans un premier temps le couplage donné par la chaîne de Markov couplée (X_n, Y_n) de matrice de transition $\overline{Q}((x_1,y_1),(x_2,y_2)) = Q(x_1,x_2)Q(y_1,y_2)$.

Montrons à présent que $\overline{Q}$ récurrente positive :

- Soit $x, y \in E$. Alors : $\exists n_0, \forall n \geq n_0, Q^n(x,y) > 0$. En effet, comme la chaîne est irréductible, il suffit de traiter le cas où $x = y$. Comme la chaîne est apériodique, il existe n_1, m_1 avec $n_1 - m_1 = 1$ et $Q^{n_1}(x,x) > 0$ et $Q^{m_1}(x,x) > 0$. Si $m_1 = 0$, alors $n_0 = 0$ convient. Si $m_1 \geq 1$, alors, pour $0 \leq j \leq m_1 - 1$, on a $Q^{m_1^2+j}(x,x) = Q^{jn_1+(m_1-j)m_1}(x,x) > 0$, donc $n_0 = m_1^2$ convient.
- La matrice $\overline{Q}$ est irréductible. En effet, soit $x_1, x_2, y_1, y_2 \in E$. D'après ce qui précède, on peut choisir n_0 tel que, pour $n \geq n_0$, on a $Q^n(x_1,x_2) > 0$ et $Q^n(y_1,y_2) > 0$. Alors, pour $n \geq n_0$, on a $\overline{Q}_n((x_1,y_1)(x_2,y_2)) = Q^n(x_1,x_2)Q^n(y_1,y_2) > 0$, ce qui montre que $\overline{Q}$ est irréductible.
- Pour conclure, on vérifie que $\pi \otimes \pi$ est une mesure invariante finie pour $\overline{Q}$, ce qui montre que $\overline{Q}$ est récurrente positive.

En particulier, pour $x, x_0, y, y_0 \in E$, on a $\mathbb{E}_{(x,y)}[T_{(x_0,y_0)}] < \infty$.

On pose $T := \inf_{z\in E} T_{(z,z)} = \inf_{n\in\mathbb{N}}\{(X_n,Y_n) \in \Delta\}$ où Δ est la diagonale de E. Alors T est un temps d'arret pour la chaîne de Markov (X_n,Y_n). D'après ce qui précède, on a $\mathbb{E}_{(x,y)}[T] < \infty$, donc $\mathbb{P}_{(x,y)}(T < \infty) = 1$.

Ainsi, on peut poser $\tilde{X_n} = X_n$ si $n \leq T$, $\tilde{X_n} = Y_n$ si $n > T$ et $\tilde{Y_n} = Y_n$. Montrons que $(\tilde{X_n}, \tilde{Y_n})$ est un couplge de δ_x et π : soit $x, y \in E$, on a

$$\begin{aligned}
\mathbb{P}_x(\tilde{X_n} = y) &= \mathbb{P}_x(T > n, \tilde{X_n} = y) + \mathbb{P}_x(T \leq n, \tilde{X_n} = y) \\
&= \mathbb{P}_x(T > n, X_n = y) + \sum_{k=0}^{n} \sum_{z \in E} \mathbb{P}_x(T = k, X_k = z, Y_n = y) \\
&= \mathbb{P}_x(T > n, X_n = y) + \sum_{k=0}^{n} \sum_{z \in E} \mathbb{E}_x[\mathbb{1}_{T=k} \mathbb{1}_{X_k=z} \mathbb{1}_{Y_{n-k}=y} \circ \theta_k] \\
&= \mathbb{P}_x(T > n, X_n = y) + \sum_{k=0}^{n} \sum_{z \in E} \mathbb{E}_x[\mathbb{1}_{T=k} \mathbb{1}_{X_k=z} \mathbb{E}_{Y_k=z}[Y_{n-k} = y]] \text{ (Markov faible)} \\
&= \mathbb{P}_x(T > n, X_n = y) + \sum_{k=0}^{n} \sum_{z \in E} \mathbb{E}_x[\mathbb{1}_{T=k} \mathbb{1}_{X_k=z} \mathbb{E}_{X_k=z}[X_{n-k} = y]] \\
&= \mathbb{P}_x(T > n, X_n = y) + \mathbb{P}_x(T \leq n, X_n = y) \text{ en effectuant le chemin inverse} \\
&= \mathbb{P}_x(X_n = y).
\end{aligned}$$

Ainsi, d'après la proposition 2.4.9, on a

$$\begin{aligned}
d(Q^n \delta_x, Q^n \pi) &\leq \mathbb{P}(\tilde{X_n} \neq \tilde{Y_n}) \\
&= \mathbb{P}_x(T > n) \\
&= \sum_{y \in E} \pi(y) \mathbb{P}_{(x,y)}(T > n).
\end{aligned}$$

Comme le dernier membre de droite converge vers 0, on a le résultat. □

3 Martingales

On va étudier maintenant un autre processus aléatoire, à savoir les martingales. On commence par étudier le paradoxe du singe savant. Considérons un alphabet fixé $A, B, ..., Z$ et l'ensemble des mots $E = \{A, B, ..., Z\}^{\mathbb{N}}$. Supposons qu'un singe tape aléatoirement sur une machine à écrire avec les lettres de l'alphabet qu'on s'est donné. Alors le paradoxe énonce qu'à un moment donné, presque sûrement le singe aura tapé l'intégralité des oeuvres de Victor Hugo. Si on note T le temps d'arrêt pour lequel le singe met un point final à son premier *Les Misérables*, la question qu'on se pose est de savoir que vaut $\mathbb{E}[T]$. Pour simplifier, dans la suite, on va plutôt étudier le temps d'arrêt pour lequel le singe écrit $ABRACADABRA$. On note T ce temps d'arrêt et on note T' celui correspondant au mot $ABRACABRADA$. Un deuxième objectif est de comprendre la différence entre T et T' et entre $\mathbb{E}[T]$ et $\mathbb{E}[T']$. Pour étudier $\mathbb{E}[T]$, on peut adopter deux points de vue, celui des chaînes de Markov, ou celui des martingales qu'on va développer à présent.

On conseille à nouveau le livre [1] comme référence pour cette partie. Un ouvrage très intéressant également est [4], dans lequel l'auteur utilise les martingales pour montrer beaucoup de résultats très généraux d'intégration.

3.1 Martingales, sur-martingales, sous-martingales

Soit (X_n) un processus aléatoire. On rappelle qu'une filtration est une suite de sous-tribus

$$\mathcal{F}_0 \subset ... \subset \mathcal{F}_n \subset ...$$

Une filtration est dite adaptée si $\sigma(X_0, ..., X_n) \subset \mathcal{F}_n$.

Définition 3.1.1. Avec ces notations, on dit que (X_n) est une martingale si X_n est L^1 et si

$$\mathbb{E}[X_{n+1}|\mathcal{F}_n] = X_n.$$

On dit que c'est une sur-martingale (respectivement une sous-martingale) si X_n est L^1 et si

$$\mathbb{E}[X_{n+1}|\mathcal{F}_n] \leq X_n$$

(respectivement $\mathbb{E}[X_{n+1}|\mathcal{F}_n] \geq X_n$).

On peut interpréter une martingale comme un jeu d'argent équitable. En effet, imaginons un jeu de casino et un joueur. On note X_n la quantité d'argent du joueur au temps n. La tribu $\mathcal{F}_n$ désigne ce que l'on sait au temps n, en particulier le résultat des parties précédentes. Alors, la propriété $\mathbb{E}[X_{n+1}|\mathcal{F}_n] = X_n$ s'interprète en disant que la moyenne des gains au temps $n+1$, en sachant ce qui s'est passé est égale à l'ensemble des gains au temps n. De même, une sur-martingale correspond à un jeu défavorable (ce qui est plus susceptible d'arriver dans un casino) et avec la même interprétation, une sous-martingale correspond aux gains du casino.

L'exemple le plus simple de martingale est celui d'une martingale fermée. Si X est une variable aléatoire L^1 et si $\mathcal{F}_n$ est une filtration, on pose $X_n = [X|\mathcal{F}_n]$. Alors, la filtration $\mathcal{F}_n$ est adpatée au processus aléatoire (X_n) et pour cette filtration, X_n est une martingale. On dit que c'est une martingale fermée.

On rappelle que si (V, E) est un graphe, on peut définir un laplacien discret en posant

$$\Delta\varphi(x) = \sum \frac{\varphi(y)}{\deg(x)} - \varphi(x),$$

où la somme est prise sur tous les voisins y de x (et $\deg(x)$ est le nombre de ces voisins) pour $\varphi : V \to \mathbb{R}$ une fonction. On dit alors qu'une fonction $\varphi : V \to \mathbb{R}$ est harmonique (respectivement sous-harmonique, sur-harmonique) si pour tout $x \in V, \Delta\varphi(x) = 0$ (respectivement $\Delta\varphi(x) \geq 0$, $\Delta\varphi(x) \leq 0$). Pour une chaîne de Markov définie sur un graphe, de matrice de transition Q, on retrouve la condition déjà étudiée $Qf = f$. Le lien avec les martingales est le suivant. Si X_n est une marche aléatoire simple sur le graphe (V, E) et φ une fonction sur V, alors $\varphi(X_n)$ est une martingale (respectivement sous-martingale, sur-martingale) si et seulement si ϕ est harmonique (respectivement sous-harmonique, sur-harmonique). Par exemple, la fonction $x \in \mathbb{Z}^d \mapsto \|x\|_2 \in \mathbb{R}$ est sous-harmonique. Ainsi, si X_n est la marche aléatoire simple sur $\mathbb{Z}^d$, alors $(\|X_n\|_2)$ est une sous-martingale. En particulier, la marche aléatoire sur $\mathbb{Z}^d$ s'éloigne de 0 comme une sous-martingale.

Un autre exemple de martingale est donné par les marches aléatoires réelles. Soient Y_i des variables aléatoires indépendantes indexées par $\mathbb{N}$. On suppose les Y_i intégrables et d'espérance nulle. Alors en posant $\mathcal{F}_n$ la tribu engendrée par les variables Y_i pour i variant de 1 à n, et en posant $X_n = \sum_{i=1}^n Y_i$, on a

$$\mathbb{E}[X_{n+1}|\mathcal{F}_n] = \mathbb{E}[X_n + Y_{n+1}|\mathcal{F}_n] = X_n + \mathbb{E}[Y_{n+1}] = X_n.$$

On a donc une martingale. Si on avait supposé les espérances positives (respectivement négatives) on aurait obtenu une sous-martingale (respectivement sur-martingale).

Remarquons par ailleurs que si (X_n) est un processus aléatoire réel, alors (X_n) est une sur-martingale si et seulement si $(-X_n)$ est une sous-martingale.

Proposition 3.1.1. *Soit (X_n) une suite de variables aléatoires L^1. Alors (X_n) est une martingale si et seulement si pour tous entiers $0 \leq n \leq m$, $\mathbb{E}[X_m|\mathcal{F}_n] = X_n$.*

Démonstration. Le sens réciproque est clair, car il suffit de prendre $n+1$ pour m. Pour le sens direct, cela résulte du calcul suivant :

$$\mathbb{E}[X_m|\mathcal{F}_n] = \mathbb{E}[\mathbb{E}[X_m|\mathcal{F}_{m-1}]|\mathcal{F}_n].$$

On procède alors par récurrence sur $n \in \mathbb{N}$ et par récurrence sur $m \geq n$. □

Comme conséquence immédiate, on a que l'espérance d'une martingale est constante. Une autre remarque que l'on peut faire est que si la martingale est définie sur un domaine de temps fini, alors c'est une martingale fermée. En effet, si n varie entre 0 et N et si $\mathbb{E}[X_{n+1}|\mathcal{F}_n] = X_n$, alors $X_n = \mathbb{E}[X_N|\mathcal{F}_n]$.

À noter qu'on a le même résultat pour les sur-martingales et les sous-martingales, en particulier, l'espérance d'une sur-martingale est décroissante. D'autre part, la croissances ou la décroissance non pas des espérances mais du processus aléatoire lui-même donne des résultats réciproques. Explicitement, si (X_n) est un processus adapté à une filtration mesurée, intégrable et décroissant, alors (X_n) est une sur-martingale.

Proposition 3.1.2. *Soit $\varphi : \mathbb{R} \to \mathbb{R}^*$ une fonction convexe. Alors si X_n est une martingale et si $\varphi(X_n)$ est intégrable, $\varphi(X_n)$ est une sous-martingale.*

Démonstration. Par l'inégalité de Jensen conditionnelle, on obtient $\mathbb{E}[\varphi(X_{n+1})|\mathcal{F}_n] \geq \varphi(\mathbb{E}[X_{n+1}|\mathcal{F}_n])$ et comme (X_n) est une martingale, $\mathbb{E}[\varphi(X_{n+1})|\mathcal{F}_n] \geq \varphi(X_n)$. □

En particulier, en utilisant la convexité de $x \mapsto x^p$ pour $p \geq 1$, on en déduit que si (X_n) est une martingale et si $X_n \in L^p$ pour $p \geq 1$, alors $(|X_n|^p)$ est une sous-martingale.

Donnons à présent un autre exemple de martingales. On rappelle la définition d'un processus de branchement. Soient $\xi_{n,j}$ des variables aléatoires i.i.d. à valeurs dans $\mathbb{N}$ de loi μ. On définit les tribus $\mathcal{F}_0 = (\emptyset, \Omega)$ et pour $n \geq 1$, $\mathcal{F}_n = \sigma(\xi_{i,j}, j \in \mathbb{N}, i \leq n-1)$. On définit également par récurrence le processus (X_n) par

$$X_{n+1} = \sum_{k=1}^{X_n} \xi_{n,k}.$$

Alors, en calculant $\mathbb{E}[X_{n+1}|\mathcal{F}_n]$, on obtient

$$\mathbb{E}[X_{n+1}|\mathcal{F}_n] = \mathbb{E}[\sum_{j=1}^{\infty} \xi_{n,j} \mathbb{1}_{\{j \leq X_n\}} | \mathcal{F}_n] = \sum_{j=1}^{\infty} \mathbb{E}[\xi_{n,j} \mathbb{1}_{\{j \leq X_n\}} | \mathcal{F}_n],$$

puis on constate qu'on peut sortir l'indicatrice, pour obtenir

$$\mathbb{E}[X_{n+1}|\mathcal{F}_n] = \sum_{j=1}^{\infty} \mathbb{1}_{\{j \leq X_n\}} \mathbb{E}[\xi_{n,j}|\mathcal{F}_n] = X_n m$$

où on note m l'espérance commune des variables $\xi_{i,j}$. Si on pose $Z_n = \frac{X_n}{m^n}$, on obtient que (Z_n) est une martingale.

Donnons encore un autre exemple, celui des martingales produits. Soient Y_n des variables aléatoire indépendantes telles que $\mathbb{E}[Y_n] = 1$. On pose $X_n = \prod_{i=1}^n Y_i$ et on considère la filtration mesurée canonique $\mathcal{F}_n = \sigma(Y_1, ..., Y_n)$. Alors X_n est une martingale. En effet,

$$\mathbb{E}[X_{n+1}|\mathcal{F}_n] = \mathbb{E}[\prod_{i=1}^{n+1} Y_i | \mathcal{F}_n] = \prod_{i=1}^{n} Y_i \mathbb{E}[Y_{n+1}|\mathcal{F}_n] = X_n,$$

puisque par indépendance, $\mathbb{E}[Y_{n+1}|\mathcal{F}_n] = \mathbb{E}[Y_{n+1}] = 1$.

Définition 3.1.2. Soit (C_n) un processus aléatoire réel et $\mathcal{F}_n$ une filtration mesurée. On dit que (C_n) est un processus prévisible si pour tout $n \geq 1$, C_n est $\mathcal{F}_{n-1}$-mesurable et si C_n est borné presque sûrement.

Définition 3.1.3. Soient $\mathcal{F}_n$ une filtration mesurée, (X_n) un processus adapté et (C_n) un processus prévisible. On définit la transformée de martingale de X par (C_n) comme étant le processus $((C \cdot X)_n)$ défini ainsi :

— $(C \cdot X)_0 = 0$,

— $(C \cdot X)_n = C_1(X_1 - X_0) + C_2(X_2 - X_1) + ... + C_n(X_n - X_{n-1})$.

Proposition 3.1.3. *Soient $\mathcal{F}_n$ une filtration mesurée, (X_n) un processus adapté et (C_n) un processus prévisible. Alors si (X_n) est une martingale, alors $((C \cdot X)_n)$ est une martingale. Si (X_n) est une sur-martingale (respectivement une sous-martingale) et si $C_n \geq 0$, alors $((C \cdot X)_n)$ est une sur-martingale (respectivement une sous-martingale).*

Démonstration. Par hypothèse, (C_n) est presque sûrement bornée, disons par une constante k_n. Alors, si X_n est L^1 pour tout n, on obtient $|(C \cdot X)_n| \leq k_1(|X_1| + |X_0|) + ... + k_n(|X_n| + |X_{n-1}|)$ donc $((C \cdot X)_n)$ est aussi dans L^1 pour tout n. D'autre part,

$$\mathbb{E}[(C \cdot X)_{n+1}|\mathcal{F}_n] = (C \cdot X)_n + \mathbb{E}[C_{n+1}X_{n+1}|\mathcal{F}_n] - C_{n+1}X_n$$

et par indépendance, on peut sortir le C_{n+1} de l'espérance, de sorte qu'on obtient

$$\mathbb{E}[(C \cdot X)_{n+1}|\mathcal{F}_n] = (C \cdot X)_n + C_{n+1}\mathbb{E}[X_{n+1}|\mathcal{F}_n] - C_{n+1}X_n = (C \cdot X)_n$$

Pour la deuxième partie de la proposition, on procède exactement de même. □

Le théorème suivant est une motivation suffisante pour étudier les martingales.

Théorème 3.1.4. *Soit (X_n) une martingale et T un temps d'arrêt associé à la filtration mesurée $\mathcal{F}_n$, avec $T < \infty$ presque sûrement. Alors $\mathbb{E}[X_T] = \mathbb{E}[X_0]$ dans chacune des quatre situations suivantes :*

— *T est borné,*

— (X_n) *est uniformément bornée,*
— *Il existe* Y *une variable aléatoire* L^1 *telle que pour tout* n, $|X_n| \leq Y$,
— $\mathbb{E}[T] < \infty$ *et* $(|X_n - X_{n-1}|)$ *est presque sûrement uniformément bornée.*

Si on remplace martingale par sur-martingale, on obtient comme conséquence à l'une de ces quatre conditions $\mathbb{E}[X_T] \leq \mathbb{E}[X_0]$.

Démonstration. Le point clé est que $(X_{n\wedge T})$ est encore une martingale. En effet, si l'on note $C_n = \mathbb{1}_{\{T\geq n\}}$, alors (C_n) est un processus prévisible et $X_{n\wedge T} = X_0 + (C \cdot X)_n$. Dans le cas où T est borné, disons $T \leq N$, on a donc $X_T = X_{N\wedge T}$, donc X_T est intégrable et $\mathbb{E}[X_T] = \mathbb{E}[X_{N\wedge T}] = \mathbb{E}[X_{0\wedge T}] = \mathbb{E}[X_0]$. Dans les situations où (X_n) est uniformément bornée ou bornée par une variable intégrable Y (conditions 2 et 3), on conclut par convergence dominée. En effet, $(X_{n\wedge T})$ converge presque sûrement vers X_T puisque T est presque sûrement borné. Le dernier cas est un peu plus technique. Supposons donc que $\mathbb{E}[T] < \infty$ et que $(|X_n - X_{n-1}|)$ est uniformément borné presque sûrement. Notons K une borne presque sûre pour $|X_n - X_{n-1}|$. Alors $|X_{n\wedge T} - X_0| = |\sum_{k=0}^{n\wedge T}(X_k - X_{k-1})| \leq (n \wedge T)K \leq TK$. Ainsi, en notant $Y = |X_0| + KT$, on a $|X_{n\wedge T}| \leq Y$, donc on peut à nouveau conclure par convergence dominée, puisque Y est une variable intégrable. □

Exemple. On considère le problème de la ruine du joueur. Rappelons qu'une martingale correspond heuristiquement aux gains d'un joueur à un jeu équitable. Imaginons qu'un joueur s'arrête de jouer quand il est ruiné, i.e. on note τ le temps d'arrêt $\tau = \inf\{n, X_n = 0\}$. Prenons en fait un problème similaire, cette fois dans un tore. Soit (X_n) une martingale à valeurs dans $\{0, ..., N\}$, typiquement une marche aléatoire sur un tore (dans $\mathbb{Z}/N\mathbb{Z}$). On note $\tau = \inf\{n, X_n \in \{0, N\}\}$, alors $\mathbb{E}_k[X_\tau] = k$ et donc $\mathbb{P}[X_\tau = N] = \frac{k}{N}$.

Revenons à présent à notre exemple initial, celui du singe savant. On rappelle qu'on note T le temps d'arrêt pour lequel le singe écrit $ABRACADABRA$ et T' celui pour lequel il écrit $ABRACABRADA$. On va définir une martingale pour déterminer $\mathbb{E}[T]$. L'idée est de considérer un jeu où le singe gagne 25 euros lorsqu'il trouve la bonne lettre et perd 1 euro lorsqu'il se trompe (de sorte que l'espérance soit nulle). Puisque le singe tape aléatoirement et de manière uniforme, on dispose de variables i.i.d. X_k, où $X_k \in \{A, B, ..., Z\}$ suit une loi uniforme. La variable X_k correspond à la k-ième lettre tapée par le singe. On pose, pour $n \in \mathbb{N}$,

$$M_n = \sum_{j=1}^{11} 26^j \mathbb{1}_{\{X_{n-j+1}=L_1,...,X_n=L_j\}} - n.$$

Si $n \leq j-1$, on arrête l'indicatrice avant d'arriver à des variables X_l avec $l < 0$, c'est-à-dire, on considère $\{X_1 = L_{j-n+1}, ..., X_n = L_j\}$. La variable M_n définit ainsi une martingale. Heuristiquement, au temps n, on gagne 26 euros si on a écrit A, 26^2 si on a écrit RA, 26^3 pour BRA ... et on retranche n à cette somme. On retrouve bien que M_1 est égal à 25 si le singe a trouvé la bonne lettre et -1 sinon. Ainsi, $\mathbb{E}[M_1] = 0$. On applique le théorème précédent pour obtenir que $\mathbb{E}[M_T] = \mathbb{E}[M_1] = 0$. En effet, on peut borner $\mathbb{E}[T]$. On considère le temps d'arrêt T'' pour lequel le singe écrit $ABRACADABRA$ avec le A final sur un numéro de lettre divisible par 11. Par définition, $T \leq T''$. Puisqu'on a ainsi découpé les mots écrits par le singe en blocs de 11 lettres indépendants, T'' suit une loi géométrique et donc $\mathbb{E}[T] \leq 11\text{x}26^{11} < \infty$. Ainsi, $\mathbb{E}[M_T] = 0$. De même, $\mathbb{E}[M_{T'}] = 0$. Or, $M_T = 26^{11} + 26^4 + 26 - T$. En effet, quand on a lu $ABRACADABRA$, on a aussi recommencé à lire le mot avec le $ABRA$ final et avec le A final. On déduit de tout ceci que $\mathbb{E}[T] = 26^{11} + 26^4 + 26$. Pour $ABRACABRADA$, on obtient $\mathbb{E}[T'] = 26^{11} + 26$ seulement. Aussi étonnant que cela puisse paraître, on voit en moyenne plus rapidement un mot avec peu de répétitions qu'un mot avec beaucoup de répétitions. Pour approfondir cette pensée, on pourrait comparer ce phénomène au paradoxe de l'autobus.

3.2 Convergence(s) des martingales

Dans cette partie on s'intéresse aux convergences presque sûres et dans L^1. Les preuves s'appuieront sur les inégalités de Doob, assez techniques, qu'on présente maintenant. On pourra consulter [2] à ce propos.

Si (u_n) est une suite réelle (déterministe, pour l'instant) et si $a < b$ sont deux réels, on définit

$$S_1 = \inf\{n \geq 0, X_n \leq a\}, \quad T_1 = \inf\{n \geq S_1, X_n \geq b\}.$$

Puis par récurrence,

$$S_{k+1} = \inf\{n \geq T_k, X_n \leq a\}, \quad T_{k+1} = \inf\{n \geq S_{k+1}, X_n \geq b\}.$$

On définit alors

$$U_n[a,b] = \inf\{k, T_k \leq n, T_{k+1} \geq n\} = \sum_{k=1}^{\infty} \mathbb{1}_{\{T_k \leq n\}},$$

qu'on interprète comme le nombre de montées de la suite (u_n) dans l'intervalle $[a,b]$ avant le temps n. On définit également le nombre de montées dans l'intervalle $[a,b]$

$$U_\infty[a,b] = \sum_{k=1}^{\infty} \mathbb{1}_{\{T_k < \infty\}}.$$

Si (X_n) est maintenant un processus aléatoire adapté à une filtration $\mathcal{F}_n$, on définit de même les quantités S_k, T_k, U_n et U_∞. Ce sont des variables aléatoires. Les variables S_k et T_k sont des temps d'arrêt et la variable U_n est $\mathcal{F}_n$-mesurable.

Lemme 3.2.1 (inégalité des montées de Doob)**.** *Soit (X_n) une sous-martingale et soient $a < b$ deux réels. On pose $U_n[a,b]$ le nombre de montées dans l'intervalle $[a,b]$ avant le temps n de la suite (X_n). Alors,*

$$\forall n \geq 1, \mathbb{E}[U_n[a,b]] \leq \frac{1}{b-a}\left(\mathbb{E}[(X_n - a)^+] - \mathbb{E}[(X_0 - a)^+]\right).$$

Démonstration. On abrège $U_n[a,b]$ en U_n, de même pour les temps d'arrêts T_k et S_k. Définissons la variable $C_n = \sum_{k=1}^{\infty} \mathbb{1}_{\{S_k < n \leq T_k\}}$. Alors $C_n \leq 1$. D'autre part,

$$\{S_k < n \leq T_k\} = \{S_k \leq n-1\} \setminus \{T_k \leq n-1\},$$

donc C_n est $\mathcal{F}_{n-1}$-mesurable et (C_n) est un processus prévisible. On note $Y_n = (X_n - a)^+$. C'est également une sous-martingale. Calculons $(C \cdot Y)_n$:

$$(C \cdot Y)_n = \sum_{k=1}^{U_n} (Y_{T_k} - Y_{S_k}) + \mathbb{1}_{\{S_{U_n+1} < n\}}(Y_n - Y_{S_{U_n+1}}) \geq \sum_{k=1}^{U_n} (Y_{T_k} - Y_{S_k}) \geq U_n(b-a)$$

de sorte que $\mathbb{E}[(C \cdot Y)_n] \geq (b-a)\mathbb{E}[U_n]$. On note $C'_n = 1 - C_n$. Alors (C'_n) est un processus prévisible positif et borné, donc $(C' \cdot Y)_n)$ est une sous-martingale, donc

$$\mathbb{E}[(C' \cdot Y)_n] \geq \mathbb{E}[(C' \cdot Y)_0] = 0.$$

Puisque $(C \cdot Y)_n + (C' \cdot Y_n) = Y_n - Y_0$, en sommant ces deux inégalités, on obtient

$$(b-a)\mathbb{E}[U_n] \leq \mathbb{E}[(C \cdot Y)_n + (C' \cdot Y)_n] \leq \mathbb{E}[Y_n - Y_0],$$

ce qui permet de conclure. □

On peut maintenant en déduire le premier théorème de convergence des martingales :

Théorème 3.2.2. *Soit (X_n) une sur-martingale. On suppose que $\sup\{\mathbb{E}[|X_n|]\} < \infty$. Alors il existe une variable aléatoire L^1 qu'on note X_∞ telle que X_n converge presque sûrement vers X_∞. D'autre part, $\mathbb{E}[|X_\infty|] \leq \sup\{\mathbb{E}[|X_n|]\} < \infty$.*

Remarque. Le théorème reste vrai si on remplace sur-martingale par sous-martingale, puisque si (X_n) est une sous-martingale, $(-X_n)$ est une sur-martingale et réciproquement.

Démonstration. Pour deux réels $a < b$ on abrège $U_\infty[a,b]$ en U_∞. Par ce qui précède,

$$\mathbb{E}[U_\infty] \leq \frac{1}{b-a}\left(|a| + \sup\{\mathbb{E}[|X_n|]\}\right) < \infty,$$

donc $U_\infty < \infty$ presque sûrement. D'autre part, X_n ne converge pas dans $[-\infty, \infty]$ si et seulement si la limite supérieure et la limite inférieure de X_n diffèrent si et seulement s'il existe deux rationnels $a < b$ tels que

$$\liminf(X_n) < a < b < \limsup(X_n)$$

Ainsi, X_n ne converge pas si et seulement s'il existe $a < b$ tels que $U_\infty = \infty$. Ainsi l'évènement

$$\{X_n \text{ ne converge pas}\}$$

est inclus dans une réunion dénombrable d'évènements de mesure nulle, donc X_n converge presque sûrement. D'autre part, d'après le lemme de Fatou,

$$\mathbb{E}[|X_\infty|] \leq \mathbb{E}[\liminf |X_n|] \leq \liminf \mathbb{E}[|X_n|] < \infty,$$

ce qui assure que X_∞ est L^1 et donne l'inégalité annoncée dans le théorème. □

Remarquons à présent que si (X_n) est une sous-martingale et si $\sup\{\mathbb{E}[(X_n)^+]\} < \infty$, alors on a aussi que $\sup\{\mathbb{E}[|X_n|]\} < \infty$. En effet, $\mathbb{E}[X_n] = \mathbb{E}[(X_n)^+] - \mathbb{E}[(X_n)^-]$ et d'autre part, $\mathbb{E}[X_n] \geq \mathbb{E}[X_0]$, donc $\mathbb{E}[(X_k)^-] \leq \sup\{\mathbb{E}[(X_n)^+]\} - \mathbb{E}[X_0]$ et ce pour tout entier k. En particulier, une telle sous-martingale converge presque sûrement. Par conséquent, une sous-martingale négative converge presque sûrement et il en va de même pour une sur-martingale positive. On en déduit le théorème suivant.

Théorème 3.2.3. — *Une martingale positive converge presque sûrement vers une variable aléatoire intégrable.*
— *Une sur-martingale positive converge presque sûrement vers une variable aléatoire intégrable.*
— *Une sous-martingale négative converge presque sûrement vers une variable aléatoire intégrable.*

Il découle également du lemme de Fatou conditionnel que si (X_n) est une sur-martingale positive ou telle que $\sup\{\mathbb{E}[(X_n)^-]\} < \infty$, alors en notant X_∞ sa limite presque sûre, $X_n \geq \mathbb{E}[X_\infty|\mathcal{F}_n]$.

On peut en tirer une conséquence immédiate. On rappelle que si (X_n) est un processus de branchement de moyenne m, alors $(\frac{X_n}{m^n})$ est une martingale. Cette martingale est positive et on déduit de ce qui précède que $(\frac{X_n}{m^n})$ converge presque sûrement vers une variable aléatoire intégrable X_∞. Selon la position de m par rapport à 1, on en déduit la survie ou l'extinction de (X_n).

Passons maintenant à l'étude de la convergence des martingales dans les espaces L^p. Commençons par nous intéresser aux martingales L^2.

Lemme 3.2.4. *Soit (X_n) une martingale telle que $X_n \in L^2$ pour tout $n \in \mathbb{N}$, alors*

$$\mathbb{E}[X_n^2] = \mathbb{E}[X_0^2] + \sum_{k=1}^{n} \mathbb{E}[(X_k) - X_{k-1})^2].$$

Démonstration. On constate que $X_{n+1}^2 = (X_n + X_{n+1} - X_n)^2 = X_n^2 + (X_{n+1} - X_n)^2 + 2X_n(X_{n+1} - X_n)$. Il suffit donc de prouver que $\mathbb{E}[X_n(X_{n+1} - X_n)] = 0$. Or la variable $X_n(X_{n+1} - X_n)$ est L^1, on a donc $\mathbb{E}[X_n(X_{n+1} - X_n)] = \mathbb{E}[\mathbb{E}[X_n(X_{n+1} - X_n)|\mathcal{F}_n]] = \mathbb{E}[X_n\mathbb{E}[X_{n+1} - X_n|\mathcal{F}_n]] = 0$. □

On en déduit que si (X_n) est une martingale L^2, alors (X_n) est bornée dans L^2 si et seulement si la série $\sum \mathbb{E}[(X_{n+1} - X_n)^2]$ converge.

Théorème 3.2.5. *Soit (X_n) une martingale L^2. On suppose que $\sup\{\mathbb{E}[X_n^2]\} < \infty$. Alors (X_n) converge vers une variable aléatoire X_∞ dans L^2.*

Démonstration. Puisque (X_n) est une martingale bornée dans L^2 donc dans L^1, elle converge presque sûrement vers une variable $X_\infty \in L^1$. D'après le lemme précédent, on a

$$\mathbb{E}[X_{n+p}^2 - X_n^2] = \sum_{k=n+1}^{n+p} \mathbb{E}[(X_k - X_{k-1})^2]$$

et puisque la série $\sum \mathbb{E}[(X_{n+1} - X_n)^2]$ converge, on obtient que (X_n) est une suite de Cauchy dans L^2, ce qui assure que X_∞ est L^2 et qu'il y a convergence dans L^2. □

La convergence dans L^1 est plus difficile à obtenir. Intéressons nous pour l'instant à la convergence dans L^p pour $p > 1$. On va généraliser le résultat qu'on vient de donner pour les martingales L^2.

Lemme 3.2.6. *Soit (X_n) une sous-martingale et soient S et T deux temps d'arrêts. On suppose que $S \leq T$ presque sûrement et que T est presque sûrement borné. Alors, $\mathbb{E}[X_S] \leq \mathbb{E}[X_T]$.*

Démonstration. Puisque T est bornée presque sûrement, X_S et X_T sont dans L^1. On réintroduit le processus (C_n) défini par $C_n = \mathbb{1}_{\{S \leq n-1\}} - \mathbb{1}_{\{T \leq n-1\}}$. C'est un processus prévisible et si N est un entier tel que $T \leq N$ presque sûrement, alors $(C \cdot X)_N = X_T - X_S$. Or (X_n) est une sous-martingale et (C_n) est un processus prévisible borné et positif, donc $\mathbb{E}[(C \cdot X)_n] \geq 0$, i.e. $\mathbb{E}[X_T] \geq \mathbb{E}[X_S]$. □

Lemme 3.2.7 (inégalité maximale de Doob)**.** *Soit (X_n) une sous-martingale. Pour $n \in \mathbb{N}$, on pose $\overline{X}_n = \sup_{0\leq k\leq n} X_k$. Soit $a > 0$ un réel, alors $a\mathbb{P}(\overline{X}_n \geq a) \leq \mathbb{E}[X_n \mathbb{1}_{\{\overline{X}_n \geq a\}}]$.*

Remarque. Notons qu'en particulier, $a\mathbb{P}(\overline{X}_n \geq a) \leq \mathbb{E}[X_n^+] \leq \mathbb{E}[|X_n|]$. C'est une généralisation de l'inégalité de Markov.

Démonstration. Notons $T = \inf\{n \geq 0, X_n \geq a\}$. Puisque n et $n \wedge T$ sont des temps d'arrêts bornés, on peut appliquer le lemme précédent pour obtenir $\mathbb{E}[X_{n\wedge T}] \leq \mathbb{E}[X_n]$. Or, $X_{n\wedge T} \leq a\mathbb{1}_{\{\overline{X}_n \geq a\}} + X_n \mathbb{1}_{\{\overline{X}_n < a\}}$, donc $\mathbb{E}[X_{n\wedge T}] \geq a\mathbb{P}(\overline{X}_n \geq a) + \mathbb{E}[X_n \mathbb{1}_{\{\overline{X}_n < a\}}]$. Finalement, $a\mathbb{P}(\overline{X}_n \geq a) \leq \mathbb{E}[X_n(1 - \mathbb{1}_{\{\overline{X}_n < a\}}]$. □

Lemme 3.2.8. *Soit (X_n) une sous-martingale positive. Alors, en notant $\overline{X}_n = \sup_{0\leq k\leq n} X_k$, pour tout entier $n \geq 0$ et tout réel $p > 1$, $\mathbb{E}[\overline{X}_n^p] \leq \left(\frac{p}{p-1}\right)^p \mathbb{E}[X_n^p]$.*

Démonstration. Rappelons que si Z est une variable aléatoire positive, alors

$$\mathbb{E}[Z] = \int_0^\infty \mathbb{P}(Z \geq x)dx = \mathbb{E}[\int_0^\infty \mathbb{1}_{\{Z\geq x\}} dx] = \mathbb{E}[\int_0^Z dx].$$

Par un changement de variable, on a donc

$$\mathbb{E}[Z^p] = \mathbb{E}[p\int_0^Z x^{p-1}dx] = p\int_0^\infty x^{p-1}\mathbb{P}(Z \geq x)dx.$$

On a utilisé deux fois le théorème de Fubini pour les fonctions positives. On obtient donc ici

$$\mathbb{E}[\overline{X}_n^p] = p\int_0^\infty x^{p-1}\mathbb{P}(\overline{X}_n \geq x)dx \leq p\int_0^\infty x^{p-2}\mathbb{E}[X_n \mathbb{1}_{\{\overline{X}_n \geq x\}}]dx = p\mathbb{E}[X_n(\int_0^{\overline{X}_n} x^{p-2}dx)],$$

en utilisant le lemme précédent pour la dernière inégalité. On en déduit (à nouveau à l'aide le théorème de Fubini) que

$$\mathbb{E}[\overline{X}_n^p] \leq p\mathbb{E}[X_n(\int_0^{\overline{X}_n} x^{p-2}dx)] = \frac{p}{p-1}\mathbb{E}[(\overline{X}_n)^{p-1}X_n].$$

Notons q l'exposant conjugué de p, i.e. $1 = 1/p + 1/q$ et $pq = p + q$. Alors, à l'aide l'inégalité de Hölder, on obtient

$$\mathbb{E}[\overline{X}_n^p] \leq \frac{p}{p-1}\mathbb{E}[\overline{X}_n^p]^{1/q}\mathbb{E}[X_n^p]^{1/p}$$

et donc

$$\mathbb{E}[\overline{X}_n^p]^{1/p} \leq \frac{p}{p-1}\mathbb{E}[X_n^p]^{1/p},$$

ce qui permet de conclure. □

Remarque. Si (Y_n) est une martingale, on note $\tilde{Y}_n = \sup_{0\leq k\leq n}|Y_k|$. Alors, en appliquant le lemme précédent à $X_n = |Y_n|$, on obtient

$$\mathbb{E}[\tilde{Y}_n^p] \leq \left(\frac{p}{p-1}\right)^p \mathbb{E}[|Y_n|^p].$$

On peut maintenant énoncer le théorème de convergence L^p.

Théorème 3.2.9. *Soit (X_n) une martingale bornée dans L^p, $p > 1$. Alors il existe une variable aléatoire $X_\infty \in L^p$ telle que X_n converge presque sûrement et dans L^p vers X_∞.*

D'autre part, $\mathbb{E}[|X_\infty|^p] = \sup\{\mathbb{E}[|X_n|^p]\}$. Si on note $\tilde{X}_\infty = \sup|X_n|$, alors $\tilde{X}_\infty$ est également dans L^p et $\mathbb{E}[|\tilde{X}_\infty|^p] \leq \left(\frac{p}{p-1}\right)^p \mathbb{E}[|X_\infty|^p]$.

Enfin, X_n est une martingale fermée par X_∞, i.e. $X_n = \mathbb{E}[X_\infty|\mathcal{F}_n]$.

Démonstration. Puisque (X_n) est une martingale bornée dans L^p, donc dans L^1, elle converge presque sûrement vers une variable $X_\infty \in L^1$. D'autre part, si on note $\tilde{X}_n = \sup_{0\leq k\leq n}|X_k|$, $\tilde{X}_\infty = \lim\tilde{X}_n$, donc par convergence monotone L^p, on a $\tilde{X}_\infty \in L^p$ et $\tilde{X}_n$ converge vers $\tilde{X}_\infty$ dans L^p. Ainsi, d'après le lemme précédent,

$$\mathbb{E}[\tilde{X}_\infty^p] \leq \left(\frac{p}{p-1}\right)^p \sup\{\mathbb{E}[|X_n|^p]\}.$$

Or, $|X_n - X_\infty|^p \leq (|X_n| + |X_\infty|)^p \leq 2^p \tilde{X}_\infty^p$. On en déduit donc que $X_\infty \in L^p$, et par convergence dominée L^p, que X_n converge vers X_∞ dans L^p. On en déduit également que

$$\mathbb{E}[|\tilde{X}_\infty|^p] \leq \left(\frac{p}{p-1}\right)^p \mathbb{E}[|X_\infty|^p].$$

D'autre part, puisque $|X_n|^p$ est une sous-martingale, la suite $(\mathbb{E}[|X_n|^p])$ est croissante, donc par convergence L^p, $\mathbb{E}[|X_\infty^p] = \lim |X_n| = \sup |X_n|$.

Enfin, notons que l'application $Y \mapsto \mathbb{E}[Y|\mathcal{F}_n]$ 1-lipschitzienne dans L^1. Ainsi,

$$\mathbb{E}[|\mathbb{E}[X_\infty|\mathcal{F}_n] - \mathbb{E}[X_m|\mathcal{F}_n]|] \leq \|X_\infty - X_m\|_{L^1}$$

et X_m converge vers X_∞ dans L^p donc dans L^1. Ainsi, $\mathbb{E}[X_m|\mathcal{F}_n]$ converge vers $\mathbb{E}[X_\infty|\mathcal{F}_n]$. Or (X_n) est une martingale, donc $X_n = \mathbb{E}[X_m|\mathcal{F}_n]$ pour $m \geq n+1$. On obtient donc le dernier résultat du théorème, à savoir $X_n = \mathbb{E}[X_\infty|\mathcal{F}_n]$. □

Pour attaquer l'étude de la convergence L^1 des martingales, on s'intéresse à présent à la condition d'uniforme intégrabilité.

Définition 3.2.1. Soit Γ une partie de $L^1(\Omega, \mathcal{F}, \mathbb{P})$. On dit que Γ est uniformément intégrable si pour tout réel $\epsilon > 0$, il existe un réel K tel que pour toute variable aléatoire $X \in \Gamma$, $\mathbb{E}[|X|\mathbb{1}_{\{|X|>K\}}] \leq \epsilon$.

C'est équivalent à demander que la limite pour $k \to \infty$ de $\sup_{X\in\Gamma}\{\mathbb{E}[|X|\mathbb{1}_{\{|X|>k\}}]$ soit nulle. On remarque que si Γ est une partie de L^1 uniformément bornée, au sens où il existe un réel K_0 tel que pour toute variable aléatoire $X \in \Gamma$, $|X| \leq K_0$ presque sûrement, alors Γ est uniformément intégrable.

Exemple.
- — L'exemple le plus simple est celui d'un singleton. Si $X \in L^1$, alors $\{X\}$ est uniformément intégrable. En effet, par convergence dominée, $\mathbb{E}[|X|\mathbb{1}_{\{|X|>k\}}]$ tend vers 0 lorsque k tend vers l'infini. De même, si Γ est finie, alors Γ est uniformément intégrable.
- — Soit $Y \in L^1$, alors l'ensemble $\{X \in L^1, |X| \leq Y\}$ est uniformément intégrable.
- — Tout sous-ensemble borné de L^p est uniformément intégrable (exercice). Par sous-ensemble borné, on entend de norme L^p bornée.

Lemme 3.2.10. *Soit Γ une partie de $L^1(\Omega, \mathcal{F}, \mathbb{P})$. On suppose qu'il existe une fonction $\phi : \mathbb{R}^+ \to \mathbb{R}^+$ telle que $\frac{\phi(x)}{x}$ tend vers l'infini lorsque x tend vers l'infini et telle que $\sup_{X\in\Gamma}\{\mathbb{E}[\phi(|X|)] < \infty\}$. Alors Γ est uniformément intégrable.*

Démonstration. On note $M < \infty$ la borne supérieure de $\{\mathbb{E}[\phi(|X|)]\}$ pour $X \in \Gamma$. Soit $\epsilon > 0$, alors il existe $K \in \mathbb{R}$ tel que $\phi(x) \geq \frac{M}{\epsilon} \times x$ pour $x \geq K$. La variable aléatoire $|X|\mathbb{1}_{\{|X|>K\}}$ est donc plus petite que $\frac{\epsilon}{M}\phi(|X|)$ et donc $\mathbb{E}[|X|\mathbb{1}_{\{|X|>K\}}] \leq \frac{\epsilon}{M}\mathbb{E}[\phi(|X|)] \leq \epsilon$ pour $X \in \Gamma$, ce qui permet de conclure. □

La caractérisation des parties uniformément intégrables suivante est bien utile.

Proposition 3.2.11. *Soit Γ une partie bornée de L^1, i.e. de norme L^1 bornée. Alors Γ est uniformément intégrable si et seulement si*

$$\forall \epsilon > 0, \exists \delta > 0, \forall A \in \mathcal{F}, \mathbb{P}(A) < \delta \Rightarrow \sup_{X\in\Gamma}\{\mathbb{E}[|X|\mathbb{1}_A]\} \leq \epsilon.$$

Démonstration. Soit Γ une partie bornée de L^1. Supposons Γ uniformément intégrable. Soit $\epsilon > 0$ et soit $a > 0$ tel que $\sup_{X\in\Gamma}\{\mathbb{E}[|X|\mathbb{1}_{\{|X|>a\}}]\} \leq \frac{\epsilon}{2}$. Posons $\delta = \frac{\epsilon}{2a}$. Soit $A \in \mathcal{F}$ avec $\mathbb{P}(A) < \delta$. Alors $\mathbb{E}[|X|\mathbb{1}_A] \leq \mathbb{E}[|X|\mathbb{1}_{A\cap\{|X|\leq a\}}] + \mathbb{E}[|X|\mathbb{1}_{A\cap\{|X|>a\}}] \leq a\mathbb{P}(A) + \frac{\epsilon}{2} \leq \epsilon$. Récriproquement, supposons la propriété énoncée vérifiée. Alors, puisque Γ est borné dans L^1, on dispose de $C < \infty$ tel que $C \geq \mathbb{E}[|X|]$ pour $X \in \Gamma$. Soit $a > 0$ et soit $X \in \Gamma$. Par l'inégalité de Markov, on a $\mathbb{P}(|X| \geq a) \leq \frac{C}{a}$. Soit alors $\epsilon > 0$ et δ comme dans la propriété énoncée. Alors pour a tel que $\frac{C}{a} \leq \delta$, on a $\mathbb{E}[|X|\mathbb{1}_{\{|X|>a\}}] \leq \epsilon$ et ce pour tout $X \in \Gamma$, ce qui permet de conclure. □

On remarque par ailleurs qu'une famille uniformément intégrable est une partie bornée de L^1. En effet, il suffit de voir que $\mathbb{E}[|X|\mathbb{1}_{\{|X|\geq a\}}] \leq 1$ pour un certain a et pour tout X dans la partie uniformément intégrable. Les conséquences de cette proposition sont nombreuses. On va en particulier en déduire une caractérisation de la convergence L^1 des martingales.

Proposition 3.2.12. *Soit $X \in L^1$, alors $\Gamma = \{\mathbb{E}[X|\mathcal{G}], \mathcal{G}$ sous-tribu de $\mathcal{F}\}$ est une partie uniformément intégrable de $L^1(\Omega, \mathcal{F}, \mathbb{P})$.*

Démonstration. La partie Γ est bornée dans L^1 puisque $\|\mathbb{E}[X|\mathcal{G}]\|_{L^1} \leq \|X\|_{L^1}$ pour toute sous-tribu $\mathcal{G}$ de $\mathcal{F}$. D'autre part, soit $\epsilon > 0$ et soit $a > 0$, alors

$$\mathbb{E}[|\mathbb{E}[X|\mathcal{G}]|\mathbb{1}_{\{|\mathbb{E}[X\mathcal{G}]|>a\}}] \leq \mathbb{E}[\mathbb{E}[|X||\mathcal{G}]\mathbb{1}_{\{|\mathbb{E}[X|\mathcal{G}]|>a\}}],$$

donc

$$\mathbb{E}[|\mathbb{E}[X|\mathcal{G}]|\mathbb{1}_{\{|\mathbb{E}[X\mathcal{G}]|>a\}}] \leq \mathbb{E}[|X|\mathbb{1}_{\{|\mathbb{E}[X|\mathcal{G}]|>a\}}].$$

Or, d'après l'inégalité de Markov,

$$\mathbb{P}(|\mathbb{E}[X|\mathcal{G}]| > a) \leq \frac{1}{a}\mathbb{E}[|\mathbb{E}[X|\mathcal{G}]|] \leq \frac{1}{a}\mathbb{E}[\mathbb{E}[|X||\mathcal{G}]] = \frac{1}{a}\mathbb{E}[|X|].$$

Considérons un module d'uniforme intégrabilité δ pour la partie $\{X\}$ et pour ϵ. Soit $a > 0$ suffisamment grand pour que $\frac{1}{a}\mathbb{E}[|X|] < \delta$. Alors $\mathbb{P}(|\mathbb{E}[X|\mathcal{G}]| > a) \leq \delta$, donc

$$\mathbb{E}[|\mathbb{E}[X|\mathcal{G}]|\mathbb{1}_{\{|\mathbb{E}[X\mathcal{G}]|>a\}}] \leq \mathbb{E}[|X|\mathbb{1}_{\{|\mathbb{E}[X|\mathcal{G}]|>a\}}] \leq \epsilon,$$

ce qui permet de conclure. □

Proposition 3.2.13. *Soit (X_n) un processus aléatoire avec $X_n \in L^1$. On suppose que (X_n) converge en probabilité vers une variable aléatoire $X_\infty \in L^1$. Alors (X_n) converge vers X_∞ en norme L^1 si et seulement si $\{X_n\}$ est uniformément intégrable.*

Démonstration. Supposons que (X_n) converge vers X_∞ en norme L^1. Soit $\epsilon > 0$. Alors il existe $N \in \mathbb{N}$ tel que pour $n \geq N$, $\|X_n - X_N\|_{L^1} \leq \frac{\epsilon}{2}$. D'autre part, la famille $\{X_n\}$ est bornée dans L^1 et la famille finie $\{X_0, ..., X_N\}$ est uniformément intégrable, donc par ce qui précède, il existe $\delta > 0$ tel que si $\mathbb{P}(A) < \delta$, $\mathbb{E}[|X_k|\mathbb{1}_A] < \frac{\epsilon}{2}$ pour $0 \leq k \leq N$. Enfin, en combinant les deux inégalités, on obtient pour $n \geq N$, $\mathbb{E}[|X_n|\mathbb{1}_A] \leq \mathbb{E}[|X_N|\mathbb{1}_A] + \mathbb{E}[|X_n - X_N|] \leq \epsilon$, ce qui permet de conclure.

Réciproquement, supposons que $\{X_n\}$ soit uniformément intégrable. Alors $\{X_n\}$ est bornée en norme L^1, donc il en va de même pour la partie $\{X_n - X_m\}$. On en déduit que la partie $\{X_n - X_m\}$ est elle aussi uniformément intégrable. Soit alors $\epsilon > 0$. Il existe un réel K tel que $\mathbb{E}[|X_n - X_m|\mathbb{1}_{\{|X_n - X_m| \geq K\}}] \leq \epsilon$. Ainsi, on a la majoration suivante :

$$\mathbb{E}[|X_n - X_m|] \leq \mathbb{E}[|X_n - X_m|\mathbb{1}_{\{|X_n - X_m|\}\leq\epsilon}] + \mathbb{E}[|X_n - X_m|\mathbb{1}_{\{\epsilon \leq |X_n - X_m| \leq a\}}] + \mathbb{E}[|X_n - X_m|\mathbb{1}_{\{a \leq |X_n - X_m|\}}].$$

Le premier et le dernier terme dans la somme à droite sont majorés eux-mêmes par ϵ. Quant à celui du milieu, il est majoré par $a\mathbb{P}(|X_n - X_m| \geq \epsilon)$. Ce terme tend vers 0 quand n et m tendent vers l'infini d'après la convergence en probabilité de (X_n) vers X_∞. On en déduit que la suite (X_n) est de Cauchy dans L^1, donc par complétude converge vers une variable aléatoire X'_∞. Enfin, nécessairement $X'_\infty = X_\infty$ puisque la convergence L^1 implique la convergence en probabilité (et que la topologie de la convergence en probabilité est séparée). □

Théorème 3.2.14. *Soit (X_n) une martingale. Alors les conditions suivantes sont équivalentes :*
- *$\{X_n\}$ est uniformément intégrable,*
- *(X_n) converge presque sûrement et dans L^1 vers une variable aléatoire $X_\infty \in L^1$,*
- *(X_n) converge dans L^1 vers une variable aléatoire $X_\infty \in L^1$,*
- *(X_n) converge dans L^1 vers une variable aléatoire $X_\infty \in L^1$ et $X_n = \mathbb{E}[X_\infty|\mathcal{F}_n]$.*
- *(X_n) est fermée, i.e. il existe une variable aléatoire $X_\infty \in L^1$ telle que $X_n = \mathbb{E}[X_\infty|\mathcal{F}_n]$.*

Démonstration. Supposons que $\{X_n\}$ est uniformément intégrable. Alors en particulier, $\{X_n\}$ est bornée dans L^1. Puisque c'est une martingale, (X_n) converge presque sûrement vers une variable aléatoire X_∞ qui est L^1. En particulier, elle converge en probabilité vers X_∞, donc d'après la proposition précédente, elle converge en norme L^1. Réciproquement, si (X_n) converge en norme L^1, alors $\{X_n\}$ est uniformément intégrable, toujours par la proposition précédente.

D'autre part, si (X_n) converge en norme L^1, alors elle est de norme L^1 bornée donc converge presque sûrement vers une variable $X_\infty \in L^1$. Les deux limites sont alors les mêmes, car la convergence L^1 implique la convergence presque sûre le long d'une sous-suite. On a donc montré que les trois premières assertions sont équivalentes.

Supposons à présent que (X_n) converge en norme L^1 vers une variable aléatoire X_∞. Pour $m \geq n$ deux entiers, on a $X_n = \mathbb{E}[X_m|\mathcal{F}_n]$. Or, l'application $Y \mapsto \mathbb{E}[Y|\mathcal{G}]$ est une contraction dans l'espace L^1. En particulier, c'est une application continue et donc $\mathbb{E}[X_m|\mathcal{F}_n]$ converge vers $\mathbb{E}[X_\infty|\mathcal{F}_n]$. On a donc montré

que les quatre premières assertions sont équivalentes. On a de plus montré que les quatres premières assertions impliquent la dernière.

Enfin, supposons que (X_n) soit une martingale fermée. Alors, la famille $\{X_n\}$ est une sous-famille de $\{\mathbb{E}[X|\mathcal{G}], \mathcal{G} \text{ sous-tribu de } \mathcal{F}\}$ donc est uniformément intégrable. Finalement, les cinq assertions sont équivalentes. □

3.3 Quelques résultats sur les temps d'arrêts

Dans toute cette partie, si $\mathcal{F}_n$ est une filtration d'une tribu $\mathcal{F}$, si (X_n) est un processus adapté à valeurs réelles qui converge presque sûrement vers une variable aléatoire X_∞ et si T est un temps d'arrêt, on note

$$X_T := \sum_{n=0}^{\infty} \mathbb{1}_{\{T=n\}} X_n + \mathbb{1}_{\{T=\infty\}} X_\infty.$$

Proposition 3.3.1. *Avec ces notations, X_T est $\mathcal{F}_T$-mesurable.*

Démonstration. En effet, $\{X_T \in B\} \cap \{T = n\} = \{X_n \in B\} \cap \{T = n\} \in \mathcal{F}_n$ pour B un borélien réel. □

Théorème 3.3.2. *Soit (X_n) une martingale uniformément intégrable et soient S et T deux temps d'arrêt. Alors,*

- *$X_T \in L^1$, $X_T = \mathbb{E}[X_\infty|\mathcal{F}_T]$ et $\mathbb{E}[|X_T|] \leq \mathbb{E}[|X_\infty|]$,*
- *$\forall n \in \mathbb{N}$, $\mathbb{E}[X_T] = \mathbb{E}[X_\infty] = \mathbb{E}[X_n]$,*
- *Si $S \leq T$, alors $X_S = \mathbb{E}[X_T|\mathcal{F}_S]$.*

Démonstration. Tout d'abord, $X_T \in L^1$. En effet, puisque $\{X_n\}$ est une martingale uniformément intégrable, $X_n = \mathbb{E}[X_\infty|\mathcal{F}_n]$. Donc $\mathbb{E}[|X_n|] \leq \mathbb{E}[|X_\infty|]$ et donc $\mathbb{E}[|X_T|] \leq \mathbb{E}[|X_\infty|] < \infty$.

Montrons alors que $X_T = \mathbb{E}[X_\infty|\mathcal{F}_T]$. Soit $A \in \mathcal{F}_T$. Puisque X_T et X_∞ sont L^1, les interversions sommes espérances qui vont suivre sont justifiées. On a

$$\mathbb{E}[\mathbb{1}_A X_T] = \sum_{n\in\mathbb{N}} \mathbb{E}[\mathbb{1}_{A\cap\{T=n\}} X_T] + \mathbb{E}[\mathbb{1}_{A\cap\{T=\infty\}} X_\infty] = \sum_{n\in\mathbb{N}} \mathbb{E}[\mathbb{1}_{A\cap\{T=n\}} \mathbb{E}[X_\infty|\mathcal{F}_n]] + \mathbb{E}[\mathbb{1}_{A\cap\{T=\infty\}} X_\infty].$$

Or, par définition de $\mathcal{F}_T$, dans la somme, les événements $A \cap \{T = n\}$ sont $\mathcal{F}_n$-mesurables. On en déduit que

$$\mathbb{E}[\mathbb{1}_A X_T] = \sum_{n\in\mathbb{N}} \mathbb{E}[\mathbb{E}[\mathbb{1}_{A\cap\{T=n\}} X_\infty|\mathcal{F}_n]] + \mathbb{E}[\mathbb{1}_{A\cap\{T=\infty\}} X_\infty] = \sum_{n\in\mathbb{N}\cup\{\infty\}} \mathbb{E}[\mathbb{1}_{A\cap\{T=n\}} X_\infty] = \mathbb{E}[\mathbb{1}_A X_\infty].$$

Ainsi, par définition de l'espérance conditionnelle, $X_T = \mathbb{E}[X_\infty|\mathcal{F}_T]$. Le deuxième point est une conséquence immédiate du premier. Enfin, le troisième point découle du faite que si $S \leq T$, alors $\mathcal{F}_S \subset \mathcal{F}_T$. □

On peut faire deux remarques à propos de ce théorème. Tout d'abord, dans le cas où (X_n) est une martingale uniformément intégrable, puisque la limite X_∞ est intégrable, la famille

$$\{X_T, T \text{ est un temps d'arrêt}\}$$

est uniformément intégrable, en tant que sous-famille de

$$\{\mathbb{E}[X|\mathcal{G}], \mathcal{G} \text{ sous-tribu de } \mathcal{F}\}.$$

D'autre part, si (X_n) est une martingale, non nécessairement uniformément intégrable et que N est un entier fixé, alors $(X_{n\wedge N})$ est une martingale uniformément intégrable sur laquelle on peut appliquer le théorème.

Donnons à présent un deuxième résultat sur les temps d'arrêt.

Théorème 3.3.3. *Soit (X_n) une sur-martingale et soit T un temps d'arrêt. Si (X_n) est positive ou bien si (X_n) est uniformément intégrable, alors X_T est intégrable. D'autre part, si $S \leq T$ est un autre temps d'arrêt, alors dans le cas où (X_n) est uniformément intégrable, on a $X_S \geq \mathbb{E}[X_T|\mathcal{F}_S]$ et dans le cas où (X_n) est positive, on a $\mathbb{1}_{\{S<\infty\}} X_S \geq \mathbb{E}[\mathbb{1}_{\{T<\infty\}} X_T|\mathcal{F}_S]$.*

Démonstration. Plaçons tout d'abord dans le cas où (X_n) est une sur-martingale positive. Alors, par le lemme de Fatou, pour tout $N \in \mathbb{N}$, on a $\mathbb{E}[X_T] \leq \liminf \mathbb{E}[X_{T\wedge k}]$. Puisque $T \wedge k$ est un temps borné, on obtient donc $\mathbb{E}[X_T] \leq \mathbb{E}[X_0]$, donc X_T est L^1. Soit alors $S \leq T$. On notera $\tilde{X}_S := \mathbb{1}_{\{S<\infty\}} X_S$ et $\tilde{X}_T := \mathbb{1}_{\{T<\infty\}} X_T$. On suppose dans un premier temps que T est presque sûrement borné, disons par un entier N. On rappelle qu'on a montré que si (X_n) est une sous-martingale, $S \leq T$ deux temps d'arrêts presque sûrement bornés, alors $\mathbb{E}[X_S] \leq \mathbb{E}[X_T]$. On a donc ici ($(X_n)$ est une sur-martingale) $\mathbb{E}[X_S] \geq \mathbb{E}[X_T]$. Soit alors $A \in \mathcal{F}_S$. Puisque $S \leq T$, $A \in \mathcal{F}_T$. On conditionne les temps d'arrêts par A. Explicitement, on définit $S^A(\omega) = S(\omega)$ si $\omega \in A$ et $S^A(\omega) = N$ sinon. De même, on définit T^A. Puisque T^A et S^A sont aussi bornés par N, on obtient $\mathbb{E}[X_{S^A}] \geq \mathbb{E}[X_{T^A}]$, soit $\mathbb{E}[X_S \mathbb{1}_A] \geq \mathbb{E}[X_T \mathbb{1}_A]$.

À présent, si $S \leq T$ sont quelconques (non bornés), on pose $S_k = S \wedge k$, $T_k = T \wedge k$. Soit $B \in \mathcal{F}_S$, on pose $A := B \cap \{S \leq k\}$. Alors, par ce qui précède,

$$\mathbb{E}[X_{S_k}]\mathbb{1}_A] \geq \mathbb{E}[X_{T_k}\mathbb{1}_A] \geq \mathbb{E}[X_{T_k}\mathbb{1}_{B\cap\{T\leq k\}}].$$

En effet, $\{T \leq k\} \subset \{S \leq k\}$. Or, $X_{S_k} = X_S$ sur $\{S \leq k\}$ et de même pour T, donc on réécrit cette dernière inégalité

$$\mathbb{E}[X_S \mathbb{1}_{B\cap\{S\leq k\}}] \geq \mathbb{E}[X_T \mathbb{1}_{B\cap\{T\leq k\}}].$$

Alors, par simple convergence dominée, en passant à la limite on obtient

$$\mathbb{E}[X_S \mathbb{1}_{B\cap\{S<\infty\}}] \geq \mathbb{E}[X_T \mathbb{1}_{B\cap\{T<\infty\}}],$$

soit

$$\mathbb{E}[\tilde{X}_S \mathbb{1}_B] \geq \mathbb{E}[\tilde{X}_T \mathbb{1}_B].$$

Enfin, puisque $B \in \mathcal{F}_S$, $\mathbb{E}[\tilde{X}_T \mathbb{1}_B] = \mathbb{E}[\mathbb{E}[\tilde{X}_T|\mathcal{F}_S]\mathbb{1}_B]$ et puisque $\tilde{X}_S$ est $\mathcal{F}_S$ mesurable, on conclut de tout ceci que $\tilde{X}_S \geq \mathbb{E}[\tilde{X}_T|\mathbb{1}_B]$, soit ce que l'on voulait démontrer.

Plaçons nous maintenant dans le cas où la famille $\{X_n\}$ est uniformément intégrable. Dans ce cas, comme pour les martingales, on obtient que la famille est bornée dans L^1 donc converge presque sûrement, donc en probabilité vers une variable X_∞, donc converge dans L^1 vers X_∞. Puis, comme (X_n) est une sur-martingale, $X_n \geq \mathbb{E}[X_m|\mathcal{F}_n]$ pour $m \geq n$, donc $X_n \geq \mathbb{E}[X_\infty|\mathcal{F}_n]$. Posons alors $Z_n = \mathbb{E}[X_\infty|\mathcal{F}_n]$, de sorte que $Y_n := X_n - Z_n$ soit une sur-martingale positive. Alors (Z_n) est une martingale fermée qui converge presque sûrement vers X_∞, donc Y_n converge presque sûrement vers $Y_\infty = 0$. On note que $Y_T = X_T - Z_T$ et que par le premier cas qu'on a traité, Y_T est L^1. Puisqu'il en va de même de Z_T (car Z_n est une martingale fermée), on obtient que X_T est L^1.

Supposons maintenant que $S \leq T$ sont deux temps d'arrêt. Alors (Y_n) est une sur-martingale positive et $Y_\infty = 0$, donc les fonctions indicatrices des ensembles $\{S < \infty\}$ et $\{T < \infty\}$ sont superflues dans l'inégalité $\mathbb{1}_{\{S<\infty\}} Y_S \geq \mathbb{E}[\mathbb{1}_{\{T<\infty\}} X_T|\mathcal{F}_S$ qui provient du premier cas traité. En particulier, $Y_S \geq \mathbb{E}[X_T|\mathcal{F}_S]$ et puisque (Z_n) est une martingale fermée, $Z_S = \mathbb{E}[Z_T|\mathcal{F}_S]$. Ainsi, on obtient bien $X_S \geq \mathbb{E}[X_T|\mathcal{F}_S]$. □

3.4 Martingales rétrogrades

Passons maintenant à la dernière partie de ce cours qui concerne les martingales rétrogrades. Si $\mathcal{F}$ est une tribu, une **filtration rétrograde** de $\mathcal{F}$ est une suite indexée par $-\mathbb{N}$ $(\mathcal{F}_n)$ où $\mathcal{F}_n$ est une sous-tribu de $\mathcal{F}$ et pour tous $n \leq m \leq 0$, $\mathcal{F}_n \subset \mathcal{F}_m$. On pose dans ce cas $\mathcal{F}_{-\infty} := \bigcap_{n\in-\mathbb{N}} \mathcal{F}_n$. Soit (X_n) un processus aléatoire indexé par $-\mathbb{N}$. Il est dit adapté à la filtration rétrograde $\mathcal{F}_n$ si X_n est $\mathcal{F}_n$-mesurable. On dit alors que (X_n) est une **martingale rétrograde** si $X_n \in L^1$ et si pour tous $n \leq m \leq 0$, $X_n = \mathbb{E}[X_m|\mathcal{F}_n]$. On définit aussi exactement comme avant les sur-martingales rétrogrades et les sous-martingales rétrogrades.

Théorème 3.4.1. *Soit (X_n) une sur-martingale rétrograde. On suppose que (X_n) est bornée dans L^1. Alors, la famille (X_n) est uniformément intégrable. De plus, il existe une variable aléatoire $X_{-\infty} \in L^1$ telle que X_n converge presque sûrement et dans L^1 vers $X_{-\infty}$ lorsque $-n$ tend vers l'infini. Enfin, pour tout $n \in -\mathbb{N}$, $\mathbb{E}[X_n|\mathcal{F}_{-\infty}] \leq X_{-\infty}$.*

Démonstration. Soit $k \geq 1$ un entier positif fixé. On pose $X_m^k = X_{-k+m}$ et $\mathcal{F}_m^k = \mathcal{F}_m^k$, pour m un entier compris entre 0 et k. Si $m > k$, on pose $X_m^k = X_0$ et $\mathcal{F}_m^k = \mathcal{F}_0$. Alors $(X_m^k)_{m\in\mathbb{N}}$ est une sur-martingale pour la filtration $\mathcal{F}_m^k$.

On va utiliser la méthode des montées de Doob pour montrer que (X_n) converge vers $X_{-\infty}$. On reprend les mêmes notations qu'au début du paragraphe sur la convergence des martingales (3.2). Puisque $(-X_m^k)_{m\in\mathbb{N}}$ est une sous-martingale, si $a < b$, on a

$$(b-a)\mathbb{E}[U_k([a,b]] \leq \mathbb{E}[(-X_k^k - a)^+] = \mathbb{E}[(-X_0 - a)^+] \leq |a| + \mathbb{E}[|X_0|].$$

Or, on a que la limite de $U_k[a,b]$, lorsque k tend vers l'infini, est

$$U[a,b] := \sup\{k \in \mathbb{N}, \exists m_1 < n_1 < ... < m_k < n_k \leq 0, -X_{m_j} \leq a, -X_{n_j} \geq b, j \in \{1,...,k\}\}.$$

C'est le nombre total de montées de la suite $(-X_n)$ le long de $[a,b]$.

Par convergence monotone, on a donc $(b-a)\mathbb{E}[U([a,b]] \leq |a| + \mathbb{E}[|X_0|] < \infty$. Donc, pour tout $a < b$, $N[a,b]$ est fini presque sûrement et donc X_n converge presque sûrement vers une variable aléatoire $X_{-\infty}$. D'autre part, le lemme de Fatou donne que $X_{-\infty}$ est L^1.

On montre à présent que la famille est uniformément intégrable. Soit $\epsilon > 0$. La suite $(\mathbb{E}[X_{-n}])_{n\in\mathbb{N}}$ est croissante et majorée (puisque X_n est bornée dans L^1). Donc il existe $k \leq 0$, tel que pour tout $n \leq k$, $\mathbb{E}[X_n] \leq \mathbb{E}[X_k] + \frac{\epsilon}{2}$. En tant que famille finie, $\{X_k, ..., X_0\}$ est uniformément intégrable, donc il existe $a > 0$ tel que pour tout $k \leq n \leq 0$, $\mathbb{E}[|X_n|\mathbb{1}_{\{|X_n|>a\}}] < \epsilon$. Choisissons, par uniforme intégrabilité de $\{X_k\}$ un nombre $\delta > 0$ tel que pour tout événement $A \in \mathcal{F}$ tel que $\mathbb{P}(A) < \delta$, $\mathbb{E}[|X_k|\mathbb{1}_A] < \frac{\epsilon}{2}$. Soit alors $n < k$, on a

$$\mathbb{E}[|X_n|\mathbb{1}_{\{|X_n|>a\}}] = \mathbb{E}[X_n\mathbb{1}_{\{X_n>a\}}] + \mathbb{E}[-X_n\mathbb{1}_{\{X_n<-a\}}] = \mathbb{E}[X_n] - \mathbb{E}[X_n\mathbb{1}_{\{X_n\leq a\}}] - \mathbb{E}[X_n\mathbb{1}_{\{X_n<-a\}}].$$

On introduit alors X_k :

$$\mathbb{E}[|X_n|\mathbb{1}_{\{|X_n|>a\}}] \leq \mathbb{E}[X_k] + \frac{\epsilon}{2} - \mathbb{E}[\mathbb{E}[X_k|\mathcal{F}_n]\mathbb{1}_{\{X_n\leq a\}}] - \mathbb{E}[\mathbb{E}[X_k|\mathcal{F}_n]\mathbb{1}_{\{X_n<-a\}}].$$

Or, puisque $\{X_n < -a\}$ et $\{X_n \leq a\}$ sont $\mathcal{F}_n$-mesurables, on en déduit que

$$\mathbb{E}[|X_n|\mathbb{1}_{\{|X_n|>a\}}] \leq \mathbb{E}[X_k] - \mathbb{E}[X_k\mathbb{1}_{\{X_n\leq a\}}] - \mathbb{E}[X_k\mathbb{1}_{\{X_n<-a\}}] + \frac{\epsilon}{2} = \mathbb{E}[X_k\mathbb{1}_{\{X_n>a\}}] - \mathbb{E}[X_k\mathbb{1}_{\{X_n<-a\}}] + \frac{\epsilon}{2}.$$

Donc finalement,

$$\mathbb{E}[|X_n|\mathbb{1}_{\{|X_n|>a\}}] \leq \mathbb{E}[|X_k|\mathbb{1}_{\{|X_n|>a\}}] + \frac{\epsilon}{2}.$$

Alors, en utilisant l'inégalité de Markov, $\mathbb{P}(|X_n| > a) \leq \frac{C}{a}$ (où C est une borne pour les normes L^1 de la famille (X_n) par exemple). Ainsi, en choisissant a tel que $C < \delta a$, on obtient que pour $n < k$, $\mathbb{E}[|X_n|\mathbb{1}_{\{|X_n|<a\}}] < \epsilon$, ce qui permet de conclure, puisque le cas $n \geq k$ est déjà réglé.

Puisque (X_n) et uniformément intégrable et que (X_n) converge presque sûrement vers $X_{-\infty}$, donc en particulier en probabilité, (X_n) converge en norme L^1 vers $X_{-\infty}$.

Enfin, soient $n \in -\mathbb{N}$ et $A \in \mathcal{F}_{-\infty}$. Alors, pour $m \leq n$, $\mathbb{E}[X_n\mathbb{1}_A] \leq \mathbb{E}[\mathbb{E}[X_m|\mathcal{F}_n]\mathbb{1}_A] \leq \mathbb{E}[X_m\mathbb{1}_A]$. Donc $\mathbb{E}[\mathbb{E}[X_n|\mathcal{F}_{-\infty}]\mathbb{1}_A] \leq \mathbb{E}[X_m\mathbb{1}_A]$. Donc, $\mathbb{E}[\mathbb{E}[X_n|\mathcal{F}_{-\infty}]\mathbb{1}_A] \leq \mathbb{E}[X_{-\infty}\mathbb{1}_A]$. Enfin, $X_{-\infty}$ est $\mathcal{F}_{-\infty}$-mesurable donc on obtient au final $\mathbb{E}[X_n|\mathcal{F}_\infty] \leq X_{-\infty}$. □

À noter que les martingales rétrogrades sont un outil puissant. On peut par exemple montrer la loi forte des grands nombres assez facilement (voir par exemple [3], fin du chapitre 12). On conseille la lecture de [4] pour beaucoup d'autres applications des martingales à la théorie des probabilités et à la théorie de la mesure.

Conclusion

On a étudié dans ce cours deux type de processus aléatoires, les chaînes de Markov et les martingales. Ces deux processus doivent être considérés comme complémentaires plutôt que distincts. On a vu à plusieurs reprises que l'on pouvait adopter différents points de vue pour traiter un problème "aléatoire". Typiquement, une marche aléatoire est une chaîne de Markov, mais on peut aussi la voir comme une martingale, ce qui donne des informations sur sa convergence. Un autre exemple qu'on a traité dans le cours est celui du paradoxe du singe savant.

Les chaînes de Markov et les martingales sont deux pierres d'angles à la base de nombreuses théories probabilistes. Ce sont également des outils puissants. Par exemple, les martingales donnent souvent des résultats de convergence. À nouveau, on recommande chaudement la lecture de [4].

Une première suite logique pour ce cours serait une étude approfondie des marches aléatoires. On a vu très brièvement qu'on pouvait considérer des marches aléatoires dans des groupes. Étudier ces marches aléatoires donne bien souvent des informations sur le groupe lui-même. C'est un sujet très riche car il mêle des problématiques géométriques, dynamiques et probabilistes entre autres.

Une autre suite logique, plus probabiliste, serait l'étude de processus aléatoires à temps continu. C'est par exemple, dans [3], la suite des chapitres qui concernent les chaînes de Markov et les martingales. C'est également le cas de nombreuses autres références. On pourrait notamment s'intéresser au mouvement Brownien, dans l'étude duquel on retrouve les martingales.

Références

[1] Philippe Barbé et Michel Ledoux. *Probabilités*. EDP sciences, 2007.

[2] Joseph Doob. *Stochastic processes*. Wiley, 1953.

[3] Jean-François Le Gall. *Intégrations, probabilités et processus aléatoires*. https ://www.math.u-psud.fr/ jflegall/teaching.html. 2006.

[4] David Williams. *Probability with martingales*. Cambridge mathematical textbooks, 1991.